





概率论与数理统计

No.

Date

第1章 概率论的基本概念





☆注: 相互独立与互不相容的关系:

A, B 相互独立 $\Leftrightarrow P(AB) = P(A)P(B)$

A, B 互不相容 $\Leftrightarrow P(AB) = P(\emptyset) = 0$

$\therefore$ 若 $P(A) > 0, P(B) > 0$, 则相互独立和互不相容不能同时成立.

第2章 随机变量及其分布

随机变量及其分布函数

定义

随机变量: $\Omega = \{\omega\}, \forall \omega \in \Omega, X(\omega) \in \mathbb{R}$

$X(\omega) \in \mathbb{R}$

$\forall x \in \mathbb{R}, \{\omega: X(\omega) \leq x\}$ 为随机事件

$\Rightarrow X(\omega)$ 为随机变量 (简记 X)

分布函数: $F(x) = P(X \leq x)$

性质 x3

单调不减 $x_1 < x_2$ 时, $F(x_1) \leq F(x_2)$

$0 \leq F(x) \leq 1$ 且 $\begin{cases} F(-\infty) = 0 \\ F(+\infty) = 1 \end{cases}$

右连续

$\Rightarrow$ 若 $F(x)$ 满足各性质, 则可看作分布函数

性质 x7

$P(a < X \leq b) = F(b) - F(a)$

$P(X = a) = F(a) - F(a-0)$

$P(X > b) = 1 - F(b)$

.....

离散型随机变量

定义

随机变量的全部可能取值为: 有限个或可列个 $\Rightarrow$ 离散型随机变量

概率分布 (分布率): X 的全部可能取值 x_k 且取各值的概率 $P(X = x_k) = p_k$

表示方法 x2

表格

X	x_1	x_2	...	x_k	...
$P(X = x_k)$	p_1	p_2	...	p_k	...

矩阵

$$X \sim \begin{pmatrix} x_1 & x_2 & \dots & x_k & \dots \\ p_1 & p_2 & \dots & p_k & \dots \end{pmatrix}$$

满足条件

非负性: $p_k \geq 0$

归一性: $\sum_{k=1}^{\infty} p_k = 1$

与分布函数的关系

分布函数 $\xleftrightarrow{\text{确定}}$ 分布律
(为阶梯函数) $\xleftrightarrow{\text{不确定}}$

$\rightarrow (n+1)$ 段 (其中 n 为随机变量的取值个数)

帕斯卡尔分布: $P(X=k) = C_{k-1}^{r-1} (1-p)^{k-r} p^r (k=r, r+1, \dots)$

eg.

$\rightarrow r=1$ 时 $\Rightarrow$ 几何分布: $P(X=k) = (1-p)^{k-1} p (k=1, 2, \dots)$

$(X \sim G(p)) \rightarrow$ 应用于试验首次成功 (或失败) 就停止的情况

(0-1) 分布: $P(X=k) = p^k (1-p)^{1-k} (k=0, 1, 0 < p < 1)$ — 即为 $n=1$ 的伯努利分布

常用分布

二项分布 (伯努利分布) — $P(X=k) = C_n^k p^k (1-p)^{n-k}$

$X \sim B(n, p)$

其中当 $k = \begin{cases} (n+1)p \text{ 和 } (n+1)p - 1, (n+1)p \in \mathbb{Z} \\ \lfloor (n+1)p \rfloor \text{ (非整数)}, (n+1)p \notin \mathbb{Z} \end{cases}$ 时 $P(X=k)$ 取 max

泊松 (Poisson) 分布

$P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}$ (其中 $\lambda = np_n$)

$X \sim \pi(\lambda)$ 或 $X \sim p(\lambda)$

有 $\lambda = \lambda$ 和 $k = \lambda - 1$ 时 P 最大

(λ 为整数)

$\lambda \notin \mathbb{Z}$ 时, $k = \lfloor \lambda \rfloor$ 时 P 最大

连续型随机变量 (见下页)

连续型随机变量

定义 连续型随机变量 —— $F(x)$ 是 X 的分布函数, $\exists f(x) \geq 0$ 且 $F(x) = \int_{-\infty}^x f(t) dt$ $\Rightarrow$ 连续型随机变量

分布密度 (密度函数) —— 上式中的 $f(x)$ 不唯一, (非密度) 描述概率分布密集程度

性质 $\times 4$ $\left\{ \begin{array}{l} \text{非负性 } f(x) \geq 0 \\ \text{归一性 } \int_{-\infty}^{+\infty} f(x) dx = 1 \end{array} \right. \Rightarrow \text{满足这两条即可看作分布密度}$

$P(x_1 < X \leq x_2) = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x) dx \quad (x_1 < x_2)$

若 $f(x)$ 在点 x 处连续 $\Rightarrow F'(x) = f(x)$

注: $P(X=a) = \int_a^a f(x) dx = 0 \rightarrow \begin{cases} \text{不可能事件 } \Rightarrow P=0 \\ \text{必然事件 } \Rightarrow P=1 \end{cases}$

区分

离散型 —— $P(a \leq X \leq b) = \sum_{a \leq X_i \leq b} P(X=X_i) = \sum_{a \leq X_i \leq b} p_i$

连续型 —— $P(a \leq X \leq b) = F(b) - F(a) = \int_a^b f(t) dt$

eg. 柯西分布: $f(x) = \frac{1}{\pi[1+(x-a)^2]}$ 其中 a 为参数

常用分布

均匀分布 —— $f(x) = \begin{cases} \frac{1}{b-a} & (a < x < b) \\ 0 & \text{其他} \end{cases}$
 $X \sim U(a, b)$
 $F(x) = \int_{-\infty}^x f(t) dt = \begin{cases} 0 & (x < a) \\ \frac{x-a}{b-a} & (a \leq x \leq b) \\ 1 & (x \geq b) \end{cases}$

指数分布 —— $f(x) = \begin{cases} \lambda e^{-\lambda x} & (x > 0) \\ 0 & (x \leq 0) \end{cases} (\lambda > 0)$
 $X \sim E(\lambda)$
 $F(x) = \begin{cases} 1 - e^{-\lambda x} & (x > 0) \\ 0 & (x \leq 0) \end{cases}$

注: $X(t) \sim P(\lambda t)$ 可推出 $T \sim E(\lambda)$ — P_2

正态分布 (高斯分布) —— $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (-\infty < x < +\infty)$
 $X \sim N(\mu, \sigma^2)$
 $F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$

标准正态分布 ($\mu=0, \sigma=1$) —— $\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$
 $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$

公式 $\left\{ \begin{array}{l} \phi(x) = 1 - \phi(-x) \\ F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right) \Leftrightarrow F(\mu+\sigma x) = \Phi(x) \end{array} \right.$

3σ原理 —— X 落在 $(\mu-3\sigma, \mu+3\sigma)$ 的概率高达 0.9974

随机变量的函数分布

设随机变量 X 的密度函数为 $f_X(x) \quad (-\infty < x < +\infty)$, $g(x)$ 为 $(-\infty, +\infty)$ 内严格单调的可导函数, 则随机变量 $Y = g(X)$ 的密度函数 $f_Y(y) = \begin{cases} f_X(h(y)) |h'(y)| & (\alpha < y < \beta) \\ 0 & \text{其他} \end{cases}$

证明 P59 —— 其他正态分布的性质函数仍服从正态分布

第3章 多维随机变量及其分布

二维随机变量及其分布

定义：二维分布函数——性质×4 ①单调性 ②有界性 ③右连续性 ④非负性

边缘分布函数—— $F_X(x) = F(x, +\infty)$, $F_Y(y) = F(+\infty, y)$

离散型

定义： $P(X=x_i, Y=y_j) \stackrel{\text{def}}{=} p_{ij} (i, j=1, 2, \dots)$ ——联合分布律 边缘~(表格)

性质×2
非负性： $p_{ij} \geq 0$
归一性： $\sum_{i=1}^{\infty} \sum_{j=1}^{\infty} p_{ij} = 1$

联合分布律
 $F(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{ij}$
 $P(X=x_i, Y=y_j) = F(x_i, y_j) - F(x_i, y_j - 0) - F(x_i - 0, y_j) + F(x_i - 0, y_j - 0)$ 联合分布函数

求法：常用乘法公式

联合分布律 $\iff$ 边缘分布律

连续型

定义：二维连续型随机变量： $\exists f(x, y) \geq 0$ st $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$

联合密度函数——上式中的 $f(x, y)$

性质×4
 $f(x, y) \geq 0$
 $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$ $\implies$ 为联合密度

$P((X, Y) \in G) = \iint_G f(x, y) dx dy$

连续点 (x, y) 处： $\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$

边缘密度函数： $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$, $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$

常见分布

均匀分布 $(X, Y) \sim U(G)$: $f(x, y) = \begin{cases} \frac{1}{A} & (x, y) \in G \\ 0 & (x, y) \notin G \end{cases}$

正态分布 $f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}$

$(X, Y) \sim N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho) \iff X \sim N(\mu_1, \sigma_1^2) \wedge Y \sim N(\mu_2, \sigma_2^2)$

二维随机变量的条件分布

离散型条件分布

公式： $P(Y=y_j|X=x_i) = \frac{p_{ij}}{p_{i\cdot}}$, $P(X=x_i|Y=y_j) = \frac{p_{ij}}{p_{\cdot j}}$

性质×2
非负性： $P(Y=y_j|X=x_i) \geq 0$, 归一性： $\sum_{j=1}^{\infty} P(Y=y_j|X=x_i) = 1$

二维离散型的联合分布律 $\iff$ 边缘分布律及条件分布律

连续型条件分布

分布函数： $P(Y \leq y|X=x) = F_{Y|X}(y|x) = \int_{-\infty}^y f_{Y|X}(u|x) du$
(表示在 $X=x$ 条件下， Y 的分布函数在 y 这一点的函数值——积分计算)

条件密度：若 $f_Y(y)$ 在 y 处连续且 $f_Y(y) > 0$ ，则 $f_{Y|X}(x|y) = \frac{f(x, y)}{f_Y(y)}$ ($f_{Y|X}$ 类似)
 $\hookrightarrow$ 有类似全概率公式、推广贝叶斯公式(原本针对概率)

随机变量的独立性

(两变量)
定义

若对 x, y 均有 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$ 成立
($\Leftrightarrow F(x, y) = F_X(x)F_Y(y)$) $\Leftrightarrow$ 随机变量 X 和 Y 是相互独立的

$\rightarrow$ 特殊—离散型: X, Y 相互独立 $\Leftrightarrow P(X=x_i, Y=y_j) = P(X=x_i)P(Y=y_j)$
($\Leftrightarrow p_{ij} = p_{i\cdot} \cdot p_{\cdot j} (i, j=1, 2, \dots)$)

$\rightarrow$ 特殊—连续型: X, Y 相互独立 $\Leftrightarrow f(x, y) = f_X(x)f_Y(y)$ 此时边缘联合
 $\Rightarrow f_{X|Y}(x|y) = f_X(x) (f_Y(y) > 0)$

$\rightarrow$ 辨析: 两个随机变量相互独立且有相同分布 $\nRightarrow$ 两个随机变量相等. 而 $P(X=Y)=1$

反例:

X	-1	1
P	0.5	0.5

Y	-1	1
P	0.5	0.5

X, Y	-1	1
-1	0.25	0.25
1	0.25	0.25

 则 $P(X=Y) = 0.5 \neq 1$

独立性定理: 设 $f(x, y)$ 是 (X, Y) 的联合密度函数. 则 X 与 Y 相互独立

$\Leftrightarrow$ 存在非负可积函数 $r(x), g(y)$, 使得 $f(x, y) = r(x)g(y)$ 在 $f(x, y)$ 的一切连续点上成立

n 个随机变量 — 若 $X_1, X_2, \dots, X_n$ 有 $P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) = P(X_1 \leq x_1)P(X_2 \leq x_2) \dots P(X_n \leq x_n)$

($\Leftrightarrow F(x_1, x_2, \dots, x_n) = F_{X_1}(x_1)F_{X_2}(x_2) \dots F_{X_n}(x_n)$) $\Leftrightarrow X_1, X_2, \dots, X_n$ 相互独立.

(附) 正态分布相关
结论小结

若 $(X, Y) \sim N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$ 则 ① $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ (边缘)
② $X|Y=y \sim N[\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2), \sigma_1^2(1 - \rho^2)]$ (条件) ③ 可加性
 $Y|X=x \sim N[\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)]$ (条件) ④ $P_{XY} = P$ 独立 $\Leftrightarrow$ 不相关
③ X, Y 相互独立 $\Leftrightarrow \rho = 0$ (独立) ⑤ $\text{cov}(X, Y) = \sigma_1 \sigma_2 \rho_{XY} = 0$

离散型

一般方法: 当 (X, Y) 为离散型随机变量时, $Z = g(X, Y)$ 也为离散型.
 $Z = Z_K = g(X_K, Y_K), P(Z = Z_K) = P(g(X, Y) = Z_K) = \sum_{g(x_i, y_j) = Z_K} P(X=x_i, Y=y_j), K=1, 2, \dots$

特殊 $X_2: X+Y \sim B(n_1+n_2, p)$ (二项分布的可加性) $\Rightarrow X+Y \sim P(\lambda_1+\lambda_2)$ (泊松可加)

多维随机变量的
函数的分布

连续型

一般方法: $F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f(x, y) dx dy$
 $f_Z(z) = \frac{d}{dz} F_Z(z) = \frac{d}{dz} \iint_{g(x, y) \leq z} f(x, y) dx dy$

特殊

① $Z = X+Y: f_Z(z) = \int_{-\infty}^{+\infty} f_Z(z-y, y) dy = \int_{-\infty}^{+\infty} f_X(z-x) f_Y(x) dx \xrightarrow{\text{卷积}} f_X * f_Y = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx$
 $\Rightarrow$ 推广: $Z = aX + bY (a \neq 0, b \neq 0): f_Z(z) = \frac{1}{|a|} \int_{-\infty}^{+\infty} f(\frac{z-by}{a}, y) dy = \frac{1}{|b|} \int_{-\infty}^{+\infty} f(x, \frac{z-ax}{b}) dx$
★ 正态可加性: $X+Y \sim N(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2) \rightarrow$ 注意: 和的限 Z 与轴分点
② $Z = X^2+Y^2: f_Z(z) = \begin{cases} \frac{1}{2} \int_0^{\sqrt{z}} f(\sqrt{z}\cos\theta, \sqrt{z}\sin\theta) d\theta, (z > 0) \\ 0, (z \leq 0) \end{cases}$
 $Z = \frac{X}{Y} \rightarrow f_Z(z) = \int_{-\infty}^{+\infty} f(z y, y) |y| dy; Z = \frac{Y}{X} \rightarrow f_Z(z) = \int_{-\infty}^{+\infty} f(x, x z) |x| dx$
③ $M = \max(X, Y): F_M(z) = F_X(z)F_Y(z); N = \min(X, Y): F_N(z) = 1 - [1 - F_X(z)][1 - F_Y(z)]$

第4章 随机变量的数字特征.

随机变量的
数学期望

*关键:

取值与概率

相乘相加

离散型 若 $\sum_{k=1}^{\infty} x_k p_k$ 绝对收敛, 则 $E(X)$ 存在 $\rightarrow E(X) = \sum_{k=1}^{\infty} x_k p_k$.

└ 特殊 ─ 二项分布 $E(X) = np$. (特别地, $X \sim (0,1)$ 分布, $E(X) = p$)

└ 泊松分布 $E(X) = \lambda$

└ n 可分布 $E(X) = \frac{1}{p}$

连续型 若 $\int_{-\infty}^{+\infty} x f(x) dx$ 绝对收敛, 则 $E(X)$ 存在 $\rightarrow E(X) = \int_{-\infty}^{+\infty} x f(x) dx$ └ 特殊 ─ 均匀分布 设 $X \sim U(a, b) \rightarrow E(X) = \frac{a+b}{2}$ └ 指数分布 设 $X \sim E(\lambda) \rightarrow E(X) = \frac{1}{\lambda}$ └ 正态分布 设 $X \sim N(\mu, \sigma^2) \rightarrow E(X) = \mu$.随机变量函数 $Y=g(X)$ 的数学期望 $E(Y=g(X))$ 一维 $E(Y) = E[g(X)] = \sum_{k=1}^{\infty} g(x_k) p_k$ $E(Y) = E[g(X)] = \int_{-\infty}^{+\infty} g(x) f(x) dx$ 二维 $E(Z) = E[g(X, Y)] = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} g(x_i, y_j) p_{ij}$ $E(Z) = E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$ 性质 ① X 的期望存在 $\Leftrightarrow E(|X|) < +\infty$ ② X, Y 的期望存在且 $X \leq Y$, 则 $E(X) \leq E(Y)$

(可推广有限多个)

③ 线性性质: $E(C) = C$, $E(CX) = CE(X)$, $E(X+Y) = E(X) + E(Y)$ ④ X, Y 相互独立 $\Leftrightarrow E(XY) = E(X)E(Y)$ (可推广有限多个)⑤ 若正常数 a , $\forall P(X \geq a) = 1$, 则 $E(X) \geq a$.

重要的数学期望

一维 $E(X^k)$ — X 的 k 阶原点矩 $E(|X|^k)$ — X 的 k 阶绝对原点矩 $E((X-E(X))^k)$ — X 的 k 阶中心矩 $E((X-E(X))^2)$ — X 的方差, 记为 $D(X)$.二维 $E(X^k Y^l)$ — X, Y 的 $k+l$ 阶混合原点矩 $E((X-E(X))^k (Y-E(Y))^l)$ — X, Y 的 $k+l$ 阶混合中心矩 $E(XY)$ — X, Y 的二阶混合原点矩 $E[(X-E(X))(Y-E(Y))]$ — X, Y 的二阶混合中心矩 (协方差) $\frac{E[(X-E(X))(Y-E(Y))]}{\sqrt{D(X)} \sqrt{D(Y)}}$ — X, Y 的相关系数随机变量的方差
(见下页)

随机变量的方差

概念

- 偏差 — $X - E(X)$
- 方差 — $D(X) = E[X - E(X)]^2$
- 均方差(标准差) — $\sigma_X = \sqrt{D(X)}$

计算

- ① $D(X) = E[X - E(X)]^2 = \begin{cases} \sum_{k=1}^{\infty} [X_k - E(X)]^2 P(X = X_k) & \text{— 离散} \\ \int_{-\infty}^{+\infty} [X - E(X)]^2 f(x) dx & \text{— 连续} \end{cases}$
- ② $D(X) = E(X^2) - [E(X)]^2$

重要分布的方差

- 二项分布 — $D(X) = npq$
- 泊松分布 — $D(X) = \lambda$
- 均匀分布 — $D(X) = \frac{(b-a)^2}{12}$
- 指数分布 — $D(X) = \frac{1}{\lambda^2}$
- 正态分布 — $D(X) = \sigma^2$

性质

- ① 设 c 为常数, 则 $D(c) = 0$
- ② 设 X 为随机变量, c 为常数, 则 $D(cX) = c^2 D(X)$
- ③ $D(X \pm Y) = D(X) + D(Y) \pm 2\text{cov}(X, Y)$ (iff X, Y 不相关时, $D(X \pm Y) = D(X) + D(Y)$)
 → 有限个不相关: $D(X_1 + X_2 + \dots + X_n) = D(X_1) + D(X_2) + \dots + D(X_n)$
- ④ $D(X) = 0 \Leftrightarrow P(X=c) = 1$ (其中 $c = E(X)$)
- ⑤ $D(X) \leq E(X-c)^2$ (c 为常数, iff $c = E(X)$ 时等号成立)
 即 X 在 $E(X)$ 附近波动 $<$ X 在其他常数附近波动

标准化随机变量

定义: $X^* = \frac{X - E(X)}{\sqrt{D(X)}}$

性质: $E(X^*) = 0, D(X^*) = 1$. 不具有量纲.

协方差和相关系数
(见下页)

协方差和相系数

协方差 $cov(X, Y)$

相系数 r_{XY}

定义: $cov(X, Y) = E[X - E(X)][Y - E(Y)]$ (特殊地 $cov(X, X) = D(X)$)

意义: 一定程度上反映 X, Y 之间的线性相关关系

计算

- 定义: $cov(X, Y) = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} [X_i - E(X)][Y_j - E(Y)] P_{ij}$ (离散)
- $cov(X, Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [x - E(X)][y - E(Y)] f(x, y) dx dy$ (连续)
- 性质: $cov(X, Y) = E(XY) - E(X)E(Y)$
- $D(X \pm Y) = D(X) + D(Y) \pm 2cov(X, Y)$

性质

- ① 对称性 $cov(X, Y) = cov(Y, X)$
- ② 双线性性 $cov(aX, bY) = ab cov(X, Y)$
- ③ $cov(X+Y, Z) = cov(X, Z) + cov(Y, Z)$
- ④ $[cov(X, Y)]^2 \leq D(X)D(Y)$. 当 $D(X) > 0, D(Y) > 0 \rightarrow$ 对应 $|r_{XY}| \leq 1$
 当 $P\{Y - E(Y) = t_0[X - E(X)]\} = 1$ 时等号成立 $\rightarrow$ 对应 $|r_{XY}| = 1$
 $\rightarrow$ 当 $[cov(X, Y)]^2 = D(X)D(Y)$ 时, Y 与 X 有线性关系的概率为 1. 这种线性关系为 $P\left\{\frac{Y - E(Y)}{\sqrt{D(Y)}} = \pm \frac{X - E(X)}{\sqrt{D(X)}}\right\} = 1$. 即 $P(Y^* = \pm X^*) = 1$

相系数 r_{XY}

定义: $r_{XY} = \frac{cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}} = cov(X^*, Y^*) \leftarrow$ "标准化的协方差"

性质

- ① $|r_{XY}| \leq 1$
- ② $|r_{XY}| = 1 \Leftrightarrow P(Y^* = \pm X^*) = 1$
 其中 $r_{XY} = 1 \Rightarrow P(Y^* = X^*) = 1$ — 完全正相关
 $r_{XY} = -1 \Rightarrow P(Y^* = -X^*) = 1$ — 完全负相关
- ③ $|r_{XY}| \rightarrow Y$ 与 X 间线性关系强弱的度量

"不相关"

性质

- ① 独立 $\Rightarrow$ 不相关 (没有因果) (无线性关系)
- ② X 与 Y 不相关 $\Leftrightarrow cov(X, Y) = 0 \Leftrightarrow E(XY) = E(X)E(Y)$
 $\Leftrightarrow D(X \pm Y) = D(X) + D(Y)$

特殊地, 对正态分布而言, $r_{XY} = 0 \Leftrightarrow$ 不相关 $\Leftrightarrow$ 独立.

第5章 大数定律和中心极限定理

设随机变量 X 有期望 μ 和方差 σ^2 , 则对任意正数 ε , 不等式

切比雪夫不等式 定义 $P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$ (或 $P(|X - \mu| < \varepsilon) > 1 - \frac{\sigma^2}{\varepsilon^2}$)

意义: 在 μ 的 ε 邻域之外的概率不大于 $\frac{\sigma^2}{\varepsilon^2}$, 且 σ^2 大, 波动大, 在 ε 邻域外概率大

① 伯努利大数定律 定义: 设 NA 是 n 重伯努利试验中事件 A 发生的次数, p 是 A 在每次试验中发生的概率, 则 $\forall \varepsilon > 0$, 都有 $\lim_{n \rightarrow \infty} P(|\frac{NA}{n} - p| < \varepsilon) = 1$

意义: 事件 A 发生的频率“稳定于”事件 A 的概率 $\frac{NA}{n} \xrightarrow[n \rightarrow \infty]{P} p$

大数定律

“依概率收敛” 定义: 设 $Y_1, Y_2, \dots, Y_n$ 是一个随机变量序列, a 是一个常数, 若对任意正数 ε , 有 $\lim_{n \rightarrow \infty} P(|Y_n - a| < \varepsilon) = 1$, 则称序列 $Y_1, Y_2, \dots, Y_n$ 依概率收敛于 a , 记作 $Y_n \xrightarrow[n \rightarrow \infty]{P} a$

随机事件发生的频率具有稳定性

② 切比雪夫大数定律

定义: 设 $X_1, X_2, \dots, X_n, \dots$ 是一个相互独立 (或两两不相关也成立) 的随机变量序列, 每一 X_i 都有数学期望 $E(X_i)$ 和有限方差 $D(X_i)$, 且它们有公共上界 c , 即 $D(X_i) \leq c (i=1, 2, \dots)$, 则 $\forall \varepsilon > 0$, 均有

$$\lim_{n \rightarrow \infty} P\left[\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right] = 1 \quad (\text{即 } \bar{X} \xrightarrow[n \rightarrow \infty]{P} \bar{\mu})$$

推论: 独立随机变量 $X_1, X_2, \dots, X_n, \dots$ 服从同一分布且 $E(X_i) = a, D(X_i) = \sigma^2 (i=1, 2, \dots)$ 均存在, 则 $\forall \varepsilon > 0$, 均有 $\lim_{n \rightarrow \infty} P\left[\left|\frac{1}{n} \sum_{i=1}^n X_i - a\right| < \varepsilon\right] = 1$

推论意义: 当 n 足够大时, 算术平均值几乎就是一个常数, 可用算术平均值近似代替期望值

中心极限定理

③ Markov 大数定律 定义: 对随机序列 $\{X_n\}$, 若满足 $\frac{1}{n^2} D(\sum_{i=1}^n X_i) \rightarrow 0 (n \rightarrow \infty)$, 则 $\{X_n\}$ 服从大数定律

独立变量之和经标准化后的极限分布有正态分布

④ 辛钦大数定律 定义: 设 $\{X_n\}$ 为独立同分布的随机序列, 若 X_1 的数学期望存在, 则 $\{X_n\}$ 服从大数定律

中心极限定理

① 独立同分布的中心极限定理

定理: 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 服从同一分布, 具有有限的数学期望和方差. $E(X_i) = \mu, D(X_i) = \sigma^2 \neq 0 (i=1, 2, \dots)$. 则随机变量

$Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma}$ 的分布函数 $F_n(x)$ 对 $\forall x \in (-\infty, +\infty)$, 有随

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt = \Phi(x)$$

意义: 当 n 很大时, Z_n 依分布收敛 $\rightarrow N(0, 1)$

$$\sum_{i=1}^n X_i \xrightarrow{\text{依分布收敛}} \sim N(n\mu, n\sigma^2)$$

② 德莫佛-拉普拉斯定理

定理: 设随机变量 $Y_n (n=1, 2, \dots)$ 服从二项分布 $B(n, p)$, 则对于任意区间

$$(a, b) \text{ 恒有 } \lim_{n \rightarrow \infty} P\left(a < \frac{Y_n - np}{\sqrt{np(1-p)}} < b\right) = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

意义: $Y_n \sim B(np)$ 则 n 很大时, Y_n 依分布收敛 $\rightarrow \sim N(np, np(1-p))$

即正态分布是二项分布的极限分布 (①的特例)

① n 较小时 如: $n < 10$ 时 直接用二项分布计算

总结: ② n 较大而 p 较小 (或 $1-p$ 较小) 近似用 poisson 分布 近似计算 (实际要求 np 适中 一查有表可查)

③ n 较大, $0.1 < p < 0.9$ or $n > 100, p < 0.1$ 时用正态分布近似代替

$$\text{即 } P(a < Y_n < b) \approx \Phi\left(\frac{b - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - np}{\sqrt{np(1-p)}}\right)$$

$$P(Y_n = k) \approx \frac{1}{\sqrt{2\pi} \cdot \sqrt{np(1-p)}} e^{-\frac{(k - np)^2}{2np(1-p)}} \quad \text{[即区间长度} \times \text{近似概率]} \\ \text{中点}$$

第6章 数理统计的基本概念

总体; 个体; 样本; 容量; 观察值(样本值); 简单随机样本(代表性 & 独立性)

基本概念 — 统计量 定义 样本的不含未知参数的函数, 是一个随机变量.

常用统计量

样本均值: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E(X)$ 且 $E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}$

样本方差: $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) \xrightarrow{P} \sigma^2$ 且 $E(S^2) = \sigma^2$

样本标准差: $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$

样本 k 阶原点矩: $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k (k=1, 2, \dots) \xrightarrow{P} E(X^k)$

样本 k 阶中心矩: $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k (k=1, 2, \dots)$

顺序统计量 定义: 样本 $(X_1, X_2, \dots, X_n)$ 为样本 $(X_1, X_2, \dots, X_n)$ 的次序统计量

最小统计量 $X_{(1)} = \min_{1 \leq i \leq n} \{X_i\}$; 最大统计量 $X_{(n)} = \max_{1 \leq i \leq n} \{X_i\}$

样本中位数 $\tilde{X} = \begin{cases} X_{\frac{n+1}{2}} & (n \text{ 为奇数}) \\ \frac{1}{2}(X_{\frac{n}{2}} + X_{\frac{n}{2}+1}) & (n \text{ 为偶数}) \end{cases}$


样本极差: $R = X_{(n)} - X_{(1)}$ — 反映样本值和样本均值间的偏离程度

分位点 — 定义(上侧分位点): 设 X 为随机变量, 若对任意给定的 $\alpha (0 < \alpha < 1)$, 存在 $x_\alpha \in \mathbb{R}$, 使得 $P(X > x_\alpha) = \alpha$ 成立, 则称 x_α 为 X 的 α 分位点(上侧分位点)

对标准正态: $\alpha = P(U > u_\alpha) = 1 - P(U \leq u_\alpha) = 1 - \Phi(u_\alpha)$ 且 $-u_\alpha = u_{1-\alpha}$

双侧(双侧 α 分位数): 若 X 的概率密度为偶函数, 对 $\alpha (0 < \alpha < \frac{1}{2})$,

$P(|X| > x_{\frac{\alpha}{2}}) = \alpha$, 则称 $x_{\frac{\alpha}{2}}$ 为 X 所服从分布的双侧 α 分位数



抽样分布

卡方分布(χ^2) - 定义: 设 $(X_1, X_2, \dots, X_n)$ 为来自正态总体 $N(0,1)$ 的一个样本, 则称 $\chi^2 = \sum_{i=1}^n X_i^2$

为 χ^2 统计量, 且服从自由度为 n 的 χ^2 分布 $\chi^2(n)$, 记作 $\chi^2 \sim \chi^2(n)$

注: χ^2 分布的极限分布是正态分布 $\leftarrow$ 中心极限定理

性质: 可加性: 若 $\chi^2 \sim \chi^2(n_1)$, $\chi^2 \sim \chi^2(n_2)$ 且 χ^2 与 χ^2 相互独立, 则 $\chi^2 + \chi^2 \sim \chi^2(n_1 + n_2)$

若 $\chi^2 \sim \chi^2(n)$, 则 $E(\chi^2) = n$, $D(\chi^2) = 2n$

分位点: $\chi^2_{\alpha}(n)$ 查表

抽样
分布

T分布 - 定义: 设 $X \sim N(0,1)$, $Y \sim \chi^2(n)$ 且 X 和 Y 相互独立, 则 $T = \frac{X}{\sqrt{\frac{Y}{n}}}$ 称

T 统计量服从自由度为 n 的 T 分布, 记为 $T \sim t(n)$.

注: T 分布的极限分布为标准正态分布 $\leftarrow$ 中心极限定理.

性质: T 分布的密度函数 $h(t)$ 为偶函数

分位点: 有性质 $t_{1-\alpha}(n) = -t_{\alpha}(n)$ (对称性) 且 $n > 45$ 时, 有 $t_{\alpha}(n) \approx u_{\alpha}$ (正态分位点)

F分布

定义: 设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$ 且 U 和 V 相互独立, 则 $F = \frac{U/n_1}{V/n_2}$ 称为 F 统计量, 且 F 服从自由度为 n_1 , 第二自由度为 n_2 的 F 分布, 记为 $F \sim F(n_1, n_2)$.

性质: 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1) \leftarrow$ 由定义式可知

分位点: 有性质 $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$

正态分布样本
线性函数的
分布

定理: 设 $(X_1, X_2, \dots, X_n)$ 为来自正态分布 $N(\mu, \sigma^2)$ 的一个样本, 则统计量 $U = \sum_{i=1}^n A_i X_i$ 的分布仍为正态分布, 且 $E(U) = \mu \sum_{i=1}^n A_i$, $D(U) = \sigma^2 \sum_{i=1}^n A_i^2$

即 $U = \sum_{i=1}^n A_i X_i \sim N\left(\mu \sum_{i=1}^n A_i, \sigma^2 \sum_{i=1}^n A_i^2\right)$

且 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$

正态总体样本
 σ^2 的分布

$\left\{ \begin{array}{l} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1) \leftarrow \text{总体方差已知} \end{array} \right.$

$\left\{ \begin{array}{l} \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1) \leftarrow \text{总体方差未知} \end{array} \right.$

$\left\{ \begin{array}{l} \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n) \leftarrow \text{参数 } \mu \text{ 已知} \end{array} \right.$

$\left\{ \begin{array}{l} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{s} \right)^2 \sim \chi^2(n-1) \leftarrow \text{参数 } \mu \text{ 未知} \end{array} \right.$

可证 $\bar{X}$ 与 S^2 相互独立.

附：两个正态总体的抽样分布

设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $X \sim N(\mu_1, \sigma_1^2)$ 的简单随机样本

$Y_1, Y_2, \dots, Y_m$ 是来自正态总体 $Y \sim N(\mu_2, \sigma_2^2)$ 的简单随机样本，且 X 与 Y 相互独立

则有①
$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1) \quad \text{— 用于均值差的检验, 估计等.}$$

②
$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n-1, m-1) \quad \text{— 用于方差比的检验, 估计等}$$

③ 若 $\sigma_1 = \sigma_2$, 则
$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n+m} \frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}} \sim T(n+m-2)$$

— 用于特殊情形均值差的检验, 估计等.

第七章 参数估计

点估计法

矩估计法 样本k阶矩近似等于总体的k阶矩建立方程,解方程得矩法估计

理论依据: 大数定律(辛钦推论) $\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k$

最大似然估计法

推断原理: 概率最大的事件则最可能发生

思想方法: 使得一次试验就出现的事件具有最大的概率的参数作为参数真值的估计

步骤: 根据样本观察值建立似然函数

求 $L(\theta) = \max L(\theta) \leftarrow$ 对数似然函数求导求极值

得 $\theta = \theta^*$

最大似然估计的不一致性原理

设 θ 是 θ 的最大似然估计值, $u(\theta)$ 是 θ 的函数, 且具有单值的反函数 $\theta = \theta(u)$, 则 $u(\theta)$ 是 $u(\theta)$ 的最大似然估计值, 对应的统计量是估计量

无偏性

定义: 若 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是总体 X 中未知参数 θ 的一个估计量, 满足 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 是 θ 的一个无偏估计

eg. ① $\bar{x}$ 是总体期望 μ 的无偏估计

② $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 μ_k 的无偏估计

③ $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2$ 是总体方差 σ^2 的无偏估计

定义: 设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$, $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 均为 θ 的无偏估计量(前提)

若对相同的 n , 有 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效

有效性

定理: 总体 X 的数学期望为 $E(X) = \mu$, 方差 $D(X) = \sigma^2$, $(X_1, X_2, \dots, X_n)$ 为 X 的一个样本, 则有

(1) $C_1, C_2, \dots, C_n$ 为常数且 $\sum_{i=1}^n C_i = 1$ 时, $\hat{\mu} = \sum_{i=1}^n C_i X_i$ 是 μ 的无偏估计量

(2) 且 $\hat{\mu}$ 是 μ 的无偏估计 $\hat{\mu} = \sum_{i=1}^n C_i X_i$, 当 $C_1 = C_2 = \dots = C_n = \frac{1}{n}$ 时最有效

定义: 设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 为总体未知参数 θ 的一个估计量, 若 $\hat{\theta}_n$ 依概率收敛于 θ , 即 $\epsilon > 0$ 有 $\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \epsilon) = 0$, 则称 $\hat{\theta}_n$ 为 θ 的一致估计量(相合性)

一致性

(相合性)

注: 成为一致估计量不需要有具有无偏性的前提 ($\Leftrightarrow$ 有效性)


定理: 若 $\hat{\theta}_n$ 是 θ 的一个无偏估计 $E(\hat{\theta}_n) = \theta$ 时, 则只要 $\lim_{n \rightarrow \infty} D(\hat{\theta}_n) = 0$ 则 $\hat{\theta}_n$ 为 θ 的一致估计量

eg. ① $\frac{1}{n} \sum_{i=1}^n X_i^k$ 是总体 k 阶矩 μ_k 的相合估计 ② $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2$, $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{x})^2$ 都是 σ^2 的相合估计


若 $\hat{\theta}_n$ 是 θ 的无偏估计量, 则 $D(\hat{\theta}_n) \geq \frac{1}{nE[\sum_{i=1}^n \ln p(X_i)]} \triangleq I(\theta)$ 其中 $p(X_i)$ 是总体 X 的分布律或概率密度 (无偏估计, 有方差必有下界)

若存在无偏估计量 $D(\hat{\theta}) = I(\theta)$, 则称 $\hat{\theta}$ 是 θ 的有效估计 (取得到下界 $\rightarrow$ 有效估计)

Rao-Cramer不等式



第8章 假设检验



正态总体 双侧 & 单侧 假设检验. 四步骤. 记例题.

重点复习

- 第一章 { ① 概率性质
② 古典概率
③ 条件概率 } 乘法公式
全概率公式、贝叶斯公式
④ 事件的独立性

- 第二章 { ① 概率分布 定义、性质
② 常用分布
③ 随机变量函数的分布
注: 不同分布综合应用

- 第三章 { ① 联合分布
② * 边缘分布与条件分布
③ 随机变量的独立性
④ ** 随机变量的函数的分布

- 第四章 { ① 期望、方差、定义性质
② 随机变量函数期望、方差
③ 相关系数、协方差
④ 期望方差的应用
- * 取值与“概率”
相乘相加

- 第五章 { ① 切比雪夫不等式的估值作用 * 计算
② 切比雪夫大数定律
③ 独立同分布中心极限定理的应用

第六章 { ① 总体 样本 统计量的概念

② “三大抽样分布”定义、性质及分位点定义

③ 常用统计量 (或枢轴量) 的分布.

$$X \sim N(0, 1)$$

$X_1 + X_2, X_1 - X_2$ 相互独立 $\xleftarrow{P=0}$ $\left\{ \begin{array}{l} \text{Cov}(X_1 + X_2, X_1 - X_2) = \text{Cov}(X_1 + X_2, X_1) - \text{Cov}(X_1 + X_2, X_2) = 0 \\ \text{且 } X_1 + X_2, X_1 - X_2 \text{ 为正态.} \end{array} \right.$

第七章 { ① 矩估计和最大似然估计

② 参数估计的评价标准

③ 参数的区间估计

第八章 { ① 假设检验的基本思想和实施步骤

② 可能产生的两类错误及控制方法

③ 正态总体参数的单边与双边假设检验

期末 / 2分 32个

3分 12个