

大学生毕业去向预测的思路与方法

——基于机器学习算法的尝试

■孙怡帆 潘昆峰 孙正阳 何章立

摘要:出国、就业和读研是我国高校本科毕业生的三种主要去向。文章探讨了高校如何根据学生管理信息大数据,准确预测本科生毕业去向,从而提前做好本科生就业服务。研究根据我国某高水平大学2010-2015届本科生行政数据,使用机器学习领域的Lasso-Logistic算法,构建了精准度高达70%以上毕业生去向的预测模型。研究发现,性别、院系、来源地、高中文理科、高考成绩、大学期间学习成绩等因素对本科生毕业去向的预测有重要作用。研究所构建的预测模型和研究结论,其意义不仅为高校提供了通过行政大数据整合以实现学生个性化诊断预测的系统化思路,更可成为政府部门、高校精准就业服务和精准干预的决策依据。

关键词:机器学习;大学生;毕业去向;Logistic回归模型;LASSO

基金项目:2016年度教育部人文社会科学青年项目“我国高校毕业生就业迁移模式与影响因素研究”(项目编号:16YJCZH088);国家自然科学基金项目“易地教育扶贫的理论及路径研究”(项目编号:71804184)。

中图分类号:G647.38

文献标志码:A

文章编号:1674-2311(2019)1-0025-11

作者简介:孙怡帆,女,中国人民大学统计学院应用统计科学研究中心副教授;潘昆峰,男,通讯作者,中国人民大学教育学院副教授;孙正阳,女,中国人民大学统计学院硕士研究生(北京 100872);何章立,女,北京大学教育学院博士研究生(北京 100871)。

DOI:10.16477/j.cnki.issn1674-2311.2019.01.003

一、引言

近年来,我国高校毕业生每年都有较大幅度增长。根据人力资源与社会保障部数据,2017年我国高校毕业生已达到795万,^①比上年增长30万。为充分发挥大学生人力资本的优势,精准就业服务成为政府、高校及社会的共识。教育部在2016年通知要求:“高度重视精准就业服务工作”,“建立精准对接服务平台”,“实现就业服务个性化、差异化”,这

为精准就业服务提供了政策依据。^②精准就业服务的基础是学生信息的精准掌握,以及对学生选择的精准判断。纵观现有的平台和做法,基本上是根据心理测评问卷或主观填写的毕业去向意愿来进行匹配。这种匹配的思路本质上仍然是传统的人岗匹配理论,采集的仅是学生主观判断类数据,属于即时信息,却忽略了学生在大学阶段积累的多年学习与生活数据。如何合理有效利用学生成长阶段中的信息,对学生的毕业发展进行预测,从而进行

精准就业服务,现有的技术路径并不清晰。

高校毕业生的就业选择,首先是在不同的人生发展轨迹上做出选择。已有研究揭示了出国、就业、读研这三种典型选择的特征及其影响因素。虽然这些研究发现了诸如家庭背景特征会影响到学生未来选择之类的结论,但研究在预测的精准度方面并没有突出表现。基于个体调查数据的预测准确程度无从估算,从而难以满足对学生精准服务的要求。随着大数据的出现和机器学习算法的蓬勃发展,近年来国外一些有关基础教育的研究开始尝试通过使用机器学习算法提升预测准确度,从而提升学生服务和管理效果,比如针对中学生辍学问题的精准预测。^{[1][2]}然而迄今为止,在我们的搜索范围内,并没有文献指出基于机器学习算法预测高校毕业生去向的有效路径。

对于高校本科毕业生去向的预测,不仅对精准就业服务有重要作用,还能够有效利用学校信息资源,切实提升学生管理与服务水平,从而为实现“双一流”奠定良好的管理基础。基于此,本文聚焦如何通过高校学生管理行政数据来有效预测毕业生去向。在传统的logistic模型基础上,我们采用国际流行的机器学习算法——Lasso算法构建预测模型,使用我国某高水平大学长达六年的学生全样本大数据进行训练和验证,结果表明新模型具有良好的预测效果,准确率达到70%。本文的研究为应用机器学习算法预测学生行为打开了崭新的空间。

二、大学毕业选择的研究综述:人力资本理论分析及实证结论

我国在对高校进行就业率计算时,主要包括了升学、出国和工作三种类型,这三种类型都被看作是广义“就业”。仔细区分这三种类型,其中升学与出国主要对应的是继续深造。继续深造表明学生选择进行更多的人力资本投资,从而推迟了进入劳

动力市场的时间。

人力资本理论认为,何时进入劳动力市场,是理性个体最优化选择的表现。按照其观点,人力资本投资是理性决策的过程,是考虑个人或家庭在生命周期中的总效用(lifetime utility)最大化而做出的选择。^{[3][4]}个体人力资本投资的最优值(上学年限)以及投资形式(上什么样的学)对不同人而言有所不同。根据无限期模型(infinite horizon model),理性个体将会在接受教育和参加工作间做出权衡,从而决定了个体人力资本积累的最优路径。由于初始能力禀赋、个人偏好及预算约束等方面的不同,个体人力资本投资路径会有所差异。^{[5][6]}

在人力资本理论分析的基础上,实证研究对选择继续深造的个体特征进行了分析。研究表明,本科毕业推迟就业的个体在进入劳动力市场时对应着更高的受教育年限,从而具有更高的工资效应。^[7]对于此类学生特征的探讨,主要从家庭背景、个体人力资本特征、人口统计学特征三个方面进行。在家庭背景因素上,由于父母受教育水平与家庭收入水平呈正相关,而来自高收入家庭的学生负担较小,故选择深造的比例更高。最近的研究支持了家庭背景与深造可能性的关联。穆伦(Mullen)等人研究发现父母拥有高中或以下学历的学生选择深造的比例为24%,远低于父母拥有大学及以上学历的38%。^[8]针对学生个体人力资本特征的研究表明,大学阶段学习成绩(academic achievement)尤其是大学平均学分绩点(GPA)是读研的重要影响因素,^{[9][10]}成绩越高的学生越倾向于继续深造。对学生所在学校与所学专业特征的研究发现,所在学校水平越高的学生越倾向于攻读研究生学位;相比人文类专业和自然科学类专业,商科和经济学的读研比例较低。^[11]人口统计学特征的研究表明男性继续深造的比例高于女性,这表明男生比女生更倾向于做出继续深造的选择,^[12]性别差异在高端学

校入学上表现得更为明显。^[13]

出国深造作为与在本国深造完全不同的一类选择,是大学生毕业去向的重要议题。发展中国家学生为了追求更优质的高等教育资源,出国深造大多选择发达国家。^[14]对于学生能力的探讨通常认为选择出国留学的学生的人力资本水平更高。学习成绩较好,GPA较高的学生选择出国留学的可能性更大。^[15]发表论文、参与项目较多的学生科研和学习水平普遍较高,也有更大的可能性选择出国深造。然而,有研究发现,如果依照学习成绩,发表论文数量和参与项目数量进行评价,那么处于中间水平的学生拥有更高的出国深造比例,^[16]这可能是由于奇斯威克(Chiswick)所认为的优秀人才在国内也能得到优质资源,较高的出国成本会降低其出国比例。^[17]在支付能力方面,家庭收入水平是学生出国读书的重要解释变量,^[18]性别方面,女性出国深造者的数量高于男性。^[19]此外,外语水平也是影响出国深造的重要因素。^[20]

对于直接就业学生的特征研究主要围绕个体学业水平,外部经济环境和家庭背景这三方面展开。首先,毕业后直接进入劳动力市场的选择与学生自身的学业水平相关。GPA较低和对自己专业水平预期不高的学生,大学辍学可能性更大,^[21]自然地,在毕业后进行深造的概率也较小。高水平大学的学生由于学习能力较强,学术水平较高,拥有较多的深造机会,因此毕业后就业比例会低于低水平院校的毕业生。对中国高校本科毕业生的研究显示,就读于“985”院校的学生就业比例远低于专科院校。^[22]其次,学生毕业时就业市场的经济环境直接影响学生的就业选择。^[23]研究表明选择深造的入学率与经济状况呈反周期现象,^[24]即经济状况由好转坏时,继续深造的比率会降低,而当经济状况由坏转好时,继续深造的比例会升高。此外,来自收入较低家庭的学生面临的经济压力更大,故可能更倾向于选择就业。家境不好的学生进入优秀大

学的难度较高,所以这一群体更多地选择就业,但也很难进入高薪领域,这一特征在国外毕业生群体中体现尤为明显。^{[25][26]}

纵观大学生毕业去向的已有研究,在研究数据上,多采用全国或地区性的截面调查问卷数据,其变量的度量主要来自于自我陈述;在研究方法上,普遍采用多元logit回归模型;在研究取向上,大多是基于解释性的研究,重在探讨某些因素是否对学生选择有显著影响,而非强调去向选择的预测准确度。已有研究虽然对学生去向选择的重要影响因素进行了分析,但由于所收集的学生信息缺少客观和准确性,模型预测精度不高的问题广泛存在。本研究拟从两方面对以往研究进行补充。一方面,我们利用高校的多年行政大数据,解决了数据客观性缺失和历时性缺失问题;另一方面,我们将Lasso方法与logistic模型相结合,着眼于预测准确度而非仅基于变量的解释。

三、研究设计

(一)研究样本和数据来源

本文以2006至2011年A校入学的全体本科生为研究对象(对应2010-2015届本科毕业生)。排除港澳台和华侨出身,第二学位,以及高考成绩缺失的毕业生后,共计有13888例毕业生数据。本数据包含了A高校招生部门、教务部门、就业部门的行政数据,数据包含了学生的性别、专业、本科期间平均绩点(GPA)以及毕业去向等信息,但是并没有家庭背景等调查信息。

(二)变量

学生的毕业去向分为三类:工作、国内深造和国外深造。为了深入分析每一种去向的学生特征,我们针对每一种去向分别设定一个二分类变量作为模型因变量,即是否工作,是否在国内深造和是否在国外深造。

自变量共计38个,分为9组,依次为性别、生源地、高考、科类、学部、GPA及专业排名等。因变量组别为毕业去向,划分为工作、国内深造、出国深造3个取值。解释见表1。

表1 变量及说明

变量组别	变量名称	说明
毕业去向	工作	其中工作包括7种情形,分别为参军(入伍)、开具单位用人证明、就业实习、签署就业协议、签署劳动合同、自由职业及自主创业;国内深造分为已读博士、已读二学位,及已读硕士。
	国内深造	
	出国深造	
性别	男	
	女	
生源地	东部	东部地区:北京市、天津市、河北省、辽宁省、上海市、江苏省、浙江省、福建省、山东省、广东省、海南省;
	中部	中部地区:黑龙江省、吉林省、山西省、安徽省、江西省、河南省、湖北省、湖南省;
	西部	西部地区:广西壮族自治区、重庆市、四川省、贵州省、云南省、内蒙古自治区、西藏自治区、陕西省、甘肃省、青海省、宁夏回族自治区、新疆维吾尔自治区;
高考	国防生	录取方式
	自主招生	
	艺术特长生	
	提前批	
	统招	
	语数英成绩	高考语文、数学、英语成绩的总和,满分450
入学年份	总成绩	高考总成绩,满分750
		取值为2006-2011
科类	文科	高考科类
	理科	
	以艺术为主的其他类	
学部	理工类	大学所属院系
	人文类	
	法政类	
	经济类	
	社会学类	
	其他类	
GPA	第一学年度	$0.0 \leq \text{GPA } X_1 \leq 4.0$
	第二学年度	$0.0 \leq \text{GPA } X_2 \leq 4.0$
	第三学年度	$0.0 \leq \text{GPA } X_3 \leq 4.0$
	第四学年度	$0.0 \leq \text{GPA } X_4 \leq 4.0$
专业排名	第一学年度	--
	第二学年度	--
	第三学年度	--
	第四学年度	--

需要说明的是,上表给出的是数据中所有自变量,由于要进行变量选择,因此进入模型中的只是上表中的部分变量。

(三)回归模型说明

本研究将LASSO方法和logistic回归模型相结合,建立LASSO-Logistic预测模型。首先简述Logistic回归模型,然后介绍LASSO方法思想,最后给出LASSO-Logistic模型。

1. Logistic回归模型。大学生每种去向的预测本质上为二分类问题,由于Logistic回归模型不需要调节超参数,且最终模型易于解释,故本研究选择Logistic回归作为基础模型。模型定义如下:

$$P_i = \frac{\exp(\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi})}{1 + \exp(\beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi})}, i=1, 2, \dots, n \quad (1.1)$$

P_i 为第*i*个样本因变量取1的概率, x_{ip} 为组内第*i*个样本在第*p*个自变量上的值。

对于大学毕业生三个去向组:工作、出国、国内深造,分别建立Logistic回归模型。因变量依次为是否工作、是否出国深造、是否在国内深造,回答为“是”,赋值为1,反之为0。由此可估计出每个毕业生选择工作、出国和国内深造的可能性大小。

2. LASSO思想简介。由于本研究涉及变量较多,而真正对因变量有影响的可能仅是其中部分变量,其他变量则是冗余变量。冗余变量不仅会影响Logistic模型中变量关系的理解,也会通过多重共线性影响模型本身的预测精度和参数估计的稳健性,所以Logistic模型需要一种适应高维数据的变量选择方法。

最常用的是以逐步回归为代表的子集变量选择方法,其过程分为变量选择和参数估计。但由于后续估计步骤没有考察变量选择阶段带来的偏差,会导致方差被低估,并且子集变量选择方法往往需要重复计算多次,故在大规模高维数据中表现不佳。

LASSO (Least Absolute Shrinkage and Selection Operator) 方法是斯坦福大学教授 Tibshirani 在 1996 年基于 Breima 的非负绞除法 (Non-negative Garrote) 提出的一种带变量选择功能的回归模型参数估计方法。^[27]其主要思想是在原始最小二乘的基础上加上惩罚项,以实现回归系数的 L_1 范数控制,从而获得回归参数的稀疏解。该方法的优势在于通过增加惩罚项增强了估计的稳健性,同时又保留了回归模型的解释性。更重要的是,为我们提供了一种高效的变量选择方法。该方法在生物、医学、经济、营销等领域有广泛应用,现已成为主流的机器学习算法之一。本文使用 LASSO 方法进行参数估计与变量选择。

3. LASSO-Logistic 模型。LASSO-Logistic 模型的参数估计过程如下。考虑目标函数

$$f(\beta) = -L(\beta) + \lambda \sum_j |\beta_j| \quad (1.2)$$

右侧第一项 $L(\beta)$ 为 Logistic 模型的对数似然函数:

$$L(\beta) = \sum_{i=1}^n \left[y_i \ln \left(\frac{p_i}{1-p_i} \right) + \ln (1-p_i) \right], i=1, \dots, n$$

$$= \sum_{i=1}^n \left\{ y_i \left(\beta_0 + \sum_{j=1}^p \beta_j x_{ij} \right) - \ln [1 + \exp \left(\beta_0 + \sum_{j=1}^p \beta_j x_{ij} \right)] \right\} \quad (1.3)$$

第二项 λ 为外加参数,称为惩罚因子。可通过交叉验证方法确定出 λ 的值。最小化 $f(\beta)$, 得到系数 β 的估计值,记为 $\hat{\beta}$ 。将 $\hat{\beta}$ 带入式 (1.1), 从而可对大学毕业生的去向进行预测。

三、结果与分析

(一) 毕业去向的描述统计与分析

1. 本科生毕业去向的总体情况。2010-2015 年所有毕业生中近 36% 选择工作, 近 40% 选择国内读研, 近 20% 选择出国深造。三种去向的占比并非一成不变, 而是随时间推移有所变化。从 2011 年开

始, 工作不再是占比最高的选择, 国内读研则成为大学生毕业去向的首选。二者的比重随时间推移均呈现小幅下降趋势, 与此同时, 出国占比则不断升高, 如图 1 所示。




图1 2010-2015年三种毕业去向的占比

2. 毕业去向的性别差异。在国内和国外深造组中, 女性均占据约三分之二的比重, 具有绝对优势。在工作组中, 男女比例较为均衡。男性本科毕业生中近 50% 选择直接就业, 而女性中占比只有不到三成。随时间推移, 两种性别的毕业生选择工作的比例均随着年份增长而下降, 与之相对, 选择出国的比例却有明显上升。

3. 毕业去向的生源地差异。我们将毕业生生源地划分为东、中、西三类, 这三类生源地毕业生的去向选择存在较大差异 (图 2)。东部生源地的毕业




图2 2006-2011年东、中、西部毕业生毕业去向占比

生中三种毕业去向占比相对均衡。西部生源地毕业生中,选择工作的比例最高,约为出国深造的2倍。相反,中部生源地毕业生则更倾向于国内深造。对三类生源地进行横向比较发现,出国深造占比最高的是东部毕业生,最低的是中部毕业生;直接就业占比最高的是西部地区,最低的是东部地区。

4. 历时性趋势。从时间维度上看,东部毕业生选择国内深造的比例相对稳定,而出国与就业比例则有明显的上升和下降趋势。出国深造的比例增长较快,从2014年起,跃升为东部生源地毕业生去向选择的第一位(见图3(a))。相对而言,中西部生源地毕业生出国深造比例则较为稳定(见图3(b)、图3(c))。




图3(a) 2010-2015年东部生源地毕业生毕业去向变化




图3(b) 2010-2015年中部生源地毕业生毕业去向变化




图3(c) 2010-2015年西部生源地毕业生毕业去向变化

5. 毕业生所属科类与去向的关系。整体上看,出国、国内深造组中,文、理科比例均衡;工作组中,文科略占优势,占比将近55%,以艺术类为主其他科类的占比相比深造组亦有所提高(见图4)。




图4 2010-2015年三种毕业去向的毕业生所属科类占比




图5 2010-2015年毕业生三组毕业去向关于所属科类占比

不同科类毕业生的去向选择有明显差异。近40%的理科毕业生选择国内深造,工作其次,出国深造最次,且三种毕业去向占比差距较大;与之相反,文科毕业生中,国内深造与工作比例相近,只有四分之一的人出国深造。以艺术为主的其他科类中,绝大多数学生毕业后则选择就业,如图5所示。

6. 学习成绩与毕业去向的关系。柯尔莫哥洛夫-斯摩洛夫(KS)检验结果表明大一至大四每学年度GPA的分布在三个去向组别中均具有显著差异(无论哪一学年,三组KS检验的 p 值均小于0.001)。以第一学年度GPA为例,三个去向组别的GPA分布均呈现左偏特征(见图6)。工作组别第一学年度GPA的中位数要稍逊于另两个组别。国内深造组成绩内部差异较小,出国深造组与工作组内部差异较大,特别是工作组,呈现较为清晰的两极分化。由于其他学年度的GPA分布也具有相同特征,故不再赘述。




图6 2010-2015毕业生第一学年度GPA的分组箱线图

(二)LASSO-Logistic回归结果与分析

在描述性统计的基础上,我们针对毕业生是否工作、是否国外深造和是否国内深造建立3个LASSO-Logistic模型。模型将2010至2014年的数据作为训练集,2015年数据为预测集。2015年数据中三种去向占比差距较小。以下分析中均以生源地为东部地区、理科、保送生、C学院的男性毕业生为参照组。

1. 工作组LASSO-Logistic回归结果。为考察工作去向的影响因素,我们将因变量设置为0/1二分类变量,其中1表示毕业后工作,0表示其他去向。基于10-14年数据训练好Lasso-Logistic模型,称为模型1。使用模型1对15年毕业生的去向进行预测,预测效果如表2所示。该表揭示了预测结果与实际结果的符合程度。该模型预测的整体准确率为73%,其中预测为工作的准确率为67.3%,预测其他去向的准确率为74.2%。由此可见该模型具有较强的预测毕业生去向的能力。

表2 “工作”组的混淆矩阵

预测/实际	工作	其他	准确率
工作	319	155	67.3%
其他	519	1496	74.2%
综合准确率			73%

经过变量选择,模型1中共有16个自变量的系数非零且统计意义上显著(p 值 <0.05),结果见表3。相对于男性,女性本科生毕业后选择就业的几率仅为男性就业的0.877倍。换言之,男性毕业生直接工作的几率比女性高12.3%。该结果与Sax(2000)和Millett(2003)等人的研究结论相悖,他们均认为男性比女性更倾向于选择深造。^{[28][29]}此外,同等条件下来自于中西部地区的学生毕业后参加工作的几率均大于东部地区毕业生就业几率。考虑到我国中西部与东部的经济水平差异,本结论支持了Furlong(2005)及Power(2008)等人的研究成果^{[30][31]},家庭收入水平越低,毕业生越倾向于毕业后立即参加工作。就业几率会受到毕业生高考录取方式的影响,通过自主招生方式录取的学生,毕业后选择就业的几率相应增加6%。文科和其他科学生毕业后就业几率比理科生大11%左右。

学生的高考语数英综合成绩对就业选择有显著影响,其他条件固定不变的情况下,成绩每增加1分,学生毕业后选择就业的几率会随之提高7%。所学专业对毕业后选择就业的几率影响不尽相同,与

财经类专业学生相比,理工及其他类专业学生选择毕业后就业的几率略低,而人文和社科类专业学生则更倾向于选择毕业后就业。

大学阶段的学习成绩也对毕业后直接就业几率有显著影响。具体来说,除第四学年度外,其余三个学年度GPA的系数均为负,说明GPA增加将会降低毕业后直接就业的几率。这一结果印证了Millett (2003)与Zhang(2005)等人的研究发现。^{[32][33]}

表3 模型1系数估计结果

变量组别	变量名称	系数(b)	p值	Exp(b)
性别	女	-0.132	<0.001	0.877
生源地	西部	0.131	<0.001	1.141
	中部	0.092	<0.001	1.096
科类	其他	0.108	<0.001	1.114
	文科	0.111	<0.001	1.118
高考	自主招生	0.059	0.007475	1.061
	语数英综合成绩	0.070	0.0015	1.070
学部	理工学部	-0.179	<0.001	0.836
	其他学部	-0.322	<0.001	0.725
	人文学部	0.276	<0.001	1.318
	社会学部	0.188	<0.001	1.207
GPA	第一学年度	-0.301	<0.001	0.740
	第二学年度	-0.332	<0.001	0.717
	第三学年度	-0.277	<0.001	0.759
专业排名	第三学年度	0.090	0.0133	1.090
	第四学年度	0.262	<0.001	1.299

2. 国内深造组LASSO-Logistic回归结果。针对毕业生是否在国内深造我们同样利用2010-2014年数据建立LASSO-logistic模型,称为模型2。用该模型对15年毕业生去向进行预测,结果见表4。预测的整体准确率为71%,其中预测为国内深造的准确率为59.8%,预测为其他去向的准确率为77.4%。因此,该模型也同样具备一定的预测能力。

表4 国内深造组的混淆矩阵

预测/真实	国内深造	其他	准确率
国内深造	550	370	59.8%
其他	354	1215	77.4%
综合准确率			71%

模型2中共包含12个显著(p值<0.05)且具有非零系数的自变量,见表5。

表5 模型2的系数估计结果

变量组别	变量名称	系数(b)	p值	Exp(b)
性别	女	-0.128	<0.001	0.880
生源地	中部	0.103	<0.001	1.108
学部	理工学部	0.156	<0.001	1.169
	其他学部	0.366	<0.001	1.441
	人文学部	-0.184	<0.001	0.832
	社会学部	-0.115	<0.001	0.891
GPA	第一学年度	0.297	<0.001	1.346
	第二学年度	0.447	<0.001	1.563
	第三学年度	0.396	<0.001	1.485
	第四学年度	0.154	<0.001	1.167
专业排名	第三学年度	-0.176	<0.001	0.839
	第四学年度	-0.201	<0.001	0.818

根据模型回归结果,可得到如下讨论:性别是本科生毕业后是否选择在国内深造的影响因素。同等条件下,男性比女性毕业生更倾向于在国内深造。生源地方面,仅来自于中部地区的毕业生选择国内深造的几率显著高于东部地区毕业生,其他地区则与东部地区无显著差异。学生就读专业对学生毕业后是否选择国内读研也有显著影响。理工和其他类专业均对国内读研去向具有正向作用,人文和社科类专业则具有负作用。具体地,同等条件下,相比财经专业的学生,理工和其他专业的学生毕业后继续在国内读研的几率分别增加16.9%及44.1%,而人文和社科类专业学生毕业后在国内读研的几率分别减少16.9%与10.9%。我们的研究提出了与English及Umbach等人(2016)不同的观点,^[34]后者认为,相对于财经专业的学生,自然科学类学生读研比例更低。

本科阶段的学习成绩与学生毕业后国内读研的意向显著相关:每个学年度的GPA越高,国内读研的可能性越大。其中,第二学年度GPA对该意向的影响最大。第三、四学年度的专业排名也对国内读研意向有影响:排名越靠前的学生毕业后选择国内

读研的可能性越大。

3. 国外深造组 LASSO-Logistic 回归结果。我们将同样方法也应用在国外深造组上。结果表明 LASSO-logistic 模型将测试集中的所有学生去向均预测为其他去向,如表6所示,说明该模型在预测毕业生是否赴国外深造方面失效。主要有两方面原因,一是模型中未纳入对国外深造有显著影响的自变量,二是自变量与因变量之间的关系远非 logistic 模型所假设的那样。

表6 出国组 LASSO-logistic 模型的混淆矩阵

预测/真实	出国深造	其他	准确率
出国深造	0	0	/
其他	747	1742	70%
综合准确率			/

(1) 解决方案1:GBDT 方法。我们改用 GBDT 方法对学生是否出国深造进行预测。GBDT 方法全称为 Gradient Boosting Decision Tree,^[35]是一种基于迭代的决策树算法,由多棵决策树组成,将所有树所得结论进行综合得到最终判定结果。相对 logistic 回归,GBDT 方法的适用范围更广。我们利用 2010-2014 年的数据训练出模型,仍然用 2015 年数据检验模型的预测效果,结果如表7所示。

表7 深造组 GBDT 方法的混淆矩阵

预测/真实	出国深造	其他	准确率
出国深造	114	114	50%
其他	633	1628	72%
综合准确率			70%

对比表6可以发现,就预测效果来看,GBDT 方法远优于 LASSO-Logistic 模型(综合准确率=70%)。这说明毕业生是否出国深造同样可以被很好地预测。但由于 GBDT 方法无法像 LASSO-logistic 模型一样量化每个自变量对因变量的作用,故在解释性上要逊于 LASSO-logistic 模型。因此,为兼顾结果的解释性与预测的准确性,我们仍需寻找其他解决方案。

(2) 解决方案2:深造组的去向预测。我们假定

学生决定毕业去向并非一蹴而就,而是分两步进行:先决定是否继续深造,然后再决定在国内还是国外深造。是否深造的预测结果及影响因素已在前文中给出,本节不再赘述。接下来,我们将注意力放在深造组学生上,预测其毕业后将在国内或赴国外深造。具体地,将 2010-2014 年所有深造组样本作为训练集,构建出 LASSO-logistic 模型,该模型对测试集的预测效果如下表所示。

表8 深造组 LASSO-logistic 模型的混淆矩阵

预测/真实	国内深造	国外深造	准确率
国内深造	189	78	70.8%
国外深造	558	826	59.7%
综合准确率			61.5%

针对深造组,LASSO-Logistic 模型预测为国外深造的准确率为 59.7%,预测为国内深造的准确率为 70.8%,预测的整体准确率为 61.5%。由此可见该模型具备一定区分深造组学生去向的能力。

表9 深造组系数估计结果

变量组别	变量名称	系数(b)	p 值	Exp(b)
性别	女	-0.250	<0.001	0.779
地域	西部	0.153	<0.001	1.165
	中部	0.225	<0.001	1.252
高考	自主招生	0.098	<0.001	1.103
	总成绩	0.049	0.056	1.050
学部	理工学部	0.075	0.006	1.077
	其他学部	0.340	<0.001	1.491
GPA	第一学年度	0.139	0.001	1.145
	第二学年度	0.260	<0.001	1.297
	第三学年度	0.225	<0.001	1.253
	第四学年度	0.130	<0.001	1.138
专业排名	第三学年度	-0.142	0.001	0.868

该模型最终选出 12 个变量,这些变量都对深造目的地(国内/国外)的选择具有显著影响。继续深造的毕业生中,女性相比男性更倾向于赴国外深造,这与 Bandyopadhyay(2015)的观点不谋而合。^[36]具体地,同等条件下,女性毕业生赴国外深造的几

率比男性高22%。此外,东部学生相比中西部学生更愿意出国深造。各种录取方式中,只有自主招生与保送生在深造地选择中有显著差异。相比自主招生的学生,保送生在其决定深造后更偏向于选择赴国外深造。尽管时间已过去四年,但高考成绩依然对深造目的地偏好具有显著影响:高考成绩越低,赴国外深造的可能性也越大。大学前三学年的成绩也会影响深造去向。总体来讲,GPA越低的学生毕业后选择国外深造的几率越大。这与Wu (2014)的结果相反,^[37]其认为,GPA越高的学生毕业后越倾向于考虑出国深造。财经类专业毕业生比理工和其他专业毕业生更愿意赴国外深造。

四、结论与展望

本文对A校2010至2015年本科毕业生毕业去向进行分析。针对就业、国内、国外深造这三类去向,分别建立LASSO-logistic模型,结果表明该模型具备有效的预测未来毕业生毕业去向的能力。关于毕业去向的影响因素,我们有如下发现:性别、生源地、高考成绩、专业以及本科阶段学习成绩等因素对毕业去向有显著影响。具体来说,相比男性毕业生,女性毕业生更倾向于赴国外深造,而直接就业和在国内深造的意愿则偏低。生源地方面,西部地区学生偏向于毕业后直接就业,中部地区学生则偏向于毕业后在国内深造,东部地区学生则偏向于毕业后赴国外深造。在深造目的地选择中,高考成绩越高的学生毕业后越愿意选择国内深造。人文、社会等专业学生毕业后倾向于直接就业,财经类专业学生则更愿意赴国外深造,理工及其他专业毕业生偏向于留在国内深造。学生在大学本科阶段的学习成绩对毕业后继续深造的可能性具有显著的正向作用。

通过以上发现,我们认为:高校可以找寻若干指示性指标,对大学生毕业选择进行有针对性的预测,进而,可以将招生服务、过程引导与就业服务进

行联动考虑。比如,从生源特征的角度考虑,生源地、性别、高考成绩、就读学院这些前定因素会直接影响未来毕业生选择,高校可以对招生指标设定有针对性的偏向。高校人才培养的过程性因素,诸如本科学习成绩的影响,需要通过培养过程去识别。通过打通招生、培养、就业三类服务,实现全过程育人、精准服务。

本文作为引入机器学习算法解决高校毕业生就业预测的初步尝试,提出了预测毕业生就业行为的有效预测模型。这一模型的提出,其意义不仅在于提供了解决高校毕业生就业预测的具体方法,更在于提出了通过高校行政大数据整合以实现学生个性化诊断预测的系统化思路。基于这一思路,各高校可以利用大数据管理平台,通过迭代算法,不断筛选出最适宜本校学生的预测模型。经过训练与优化的模型,可以帮助高校学生服务与管理者对学生毕业时的行为进行预先识别,为学校管理者采取精准服务或精准干预提供了重要的决策依据,也作为实现教育部倡导的就业精准服务的重要路径。

本文研究的不足之处在于由于仅对一所大学的毕业生进行分析,因此结论可能未必适用于其他高校。此外,本文使用的是校行政单位所提供的数据,缺少学生家庭背景信息且缺少学生的心理状况、价值观念、学习行为等信息,使得预测精确性还有可提升的空间。未来的研究者,可以在本文的基础上,横向对比多种机器学习算法的预测结果,筛选出最优算法;亦可以采用多个学校的数据,利用我们给出的算法估计预测精度。与此同时,若能将行政数据与个体调查数据有机结合,将极有助于提升模型预测准确度。

注释

①人社部:2017年高校毕业生795万 就业任务繁重[EB/OL] http://gaokao.eol.cn/news/201701/t20170124_1485406.shtml

②教育部办公厅关于开展全国普通高校毕业生精准就业服务工作的通知[EB/OL] http://www.moe.edu.cn/srsite/A15/s3265/201604/t20160401_236231.html

参考文献

- [1] Bowers A J, Sprott R. Examining the Multiple Trajectories Associated with Dropping Out of High School: A Growth Mixture Model Analysis[J]. Journal of Educational Research, 2012, 105(3): 176-195.
- [2] Bowers A J, Sprott R, Taff S A. Do We Know Who Will Drop Out? A Review of the Predictors of Dropping out of High School: Precision, Sensitivity, and Specificity[J]. High School Journal, 2012, 96(2): 77-100.
- [3] Becker G S. Investment in human capital: A theoretical analysis [J]. The journal of political economy, 1962: 9-49.
- [4] Mincer J. Schooling, earnings and experience[M]. New York: Columbia University Press, 1974.
- [5] Altonji J G, Arcidiacono P, Maurel A. The analysis of field choice in college and graduate school: Determinants and wage effects [R]. National Bureau of Economic Research, 2015.
- [6] Montgomery M. A nested logit model of the choice of a graduate business school[J]. Economics of Education Review, 2002, 21(5):471-480.
- [7] Seki M. Heterogeneous Returns to College Selectivity and the Value of Graduate Degree Attainment[J]. Available at SSRN 2520978, 2014.
- [8] Mullen A L, Goyette K A, Soares J A. Who goes to graduate school? Social and academic correlates of educational continuation after college[J]. Sociology of Education, 2003: 143-169.
- [9] [29][32]Millett C M. How Undergraduate Loan Debt Affects Application and Enrollment in Graduate or First Professional School[J]. Journal of Higher Education, 2003, 74(4): 386-427.
- [10] [33]Zhang L. Advance to graduate education: The effect of college quality and undergraduate majors[J]. The Review of Higher Education, 2005, 28(3): 313-338.
- [11] [34]English D, Umbach P D. Graduate School Choice: An Examination of Individual and Institutional Effects[J]. Review of Higher Education, 2016, 39(2): 173-+.
- [12][28]Sax L J. Undergraduate science majors: Gender differences in who goes to graduate school[J]. The Review of Higher Education, 2000, 24(2): 153-172.
- [13] Stevenson A. The male - female gap in post-baccalaureate school quality[J]. Economics of Education Review, 2013, 36: 153-165.
- [14] Bodycott P. Choosing a higher education study abroad destination What mainland Chinese parents and students rate as important[J]. Journal of research in International education, 2009, 8(3): 349-373.
- [15] [37]Wu Q. Motivations and Decision- Making Processes of Mainland Chinese Students for Undertaking Master's Programs Abroad [J]. Journal of Studies in International Education, 2014, 18(5): 426-444.
- [16] Chen Y P. Skill- Sorting, Self- Selectivity, and Immigration Policy Regime Change: Two Surveys of Chinese Graduate Students' Intention to Study Abroad[J]. The American Economic Review, 2005, 95(2): 66-70.
- [17] Chiswick B R. Are immigrants favorably self-selected?[J]. The American economic review, 1999, 89(2): 181-185.
- [18] Mazzarol T, Soutar G N. "Push- pull" factors influencing international student destination choice[J]. International Journal of Educational Management, 2002, 16(2): 82-90.
- [19][36]Bandyopadhyay S, Bandyopadhyay K. Factors Influencing Student Participation In College Study Abroad Programs[J]. Journal of International Education Research, 2015, 11(2): 87.
- [20] Goldstein S B, Kim R I. Predictors of US college students' participation in study abroad programs: A longitudinal study[J]. International Journal of Intercultural Relations, 2006, 30(4): 507-521.
- [21] Stinebrickner T, Stinebrickner R. Learning about Academic Ability and the College Dropout Decision[J]. Journal of Labor Economics, 2012, 30(4): 707-748.
- [22] Bao W, Li B. Who is Unemployed, Employed or Admitted to Graduate School; An Investigation of the Employment Situation of College Graduates in China between 2003 and 2009[J]. Chinese Education & Society, 2015, 47(6): 36-58.
- [23] Bedard K, Herman D A. Who goes to graduate/professional school? The importance of economic fluctuations, undergraduate field, and ability[J]. Economics of Education Review, 2008, 27(2): 197-210.
- [24] Dellas H, Koubi V. Business cycles and schooling[J]. European Journal of Political Economy, 2003, 19(4): 843-859.
- [25] [30] Furlong A, Cartmel F. Graduates from disadvantaged families: Early labour market experiences[M]. Bristol:Policy Press, 2005.
- [26][31]Power S A, Whitty G. Graduating and gradations within the middle class: the legacy of an elite higher education[M]. Wales:Cardiff School of Social Sciences, Cardiff University, 2008.
- [27] Tibshirani R. Regression shrinkage and selection via the lasso [J]. Journal of the Royal Statistical Society. Series B (Methodological), 1996: 267-288.
- [35]Hastie T, Friedman J, Tibshirani R. The Elements of Statistical Learning[J]. Springer, 2001: 359-360.

责任编辑:张俊