

线性


机器学习: 有经验数据, 并依据其进化行为的一种算法
如最小二乘法是机器学习, 而固定函数关系不是
机器学习, 又有算法, 且算法不固定
类型: 有监督 有标签, 要拟合模型使其逼近标签, 因此
无监督 无标签, 聚类
三驾马车: 模型 决策树, 神经网络, 支持向量机
数据 每个特征称 feature, 许多维的数据构成 vector
算法

独立同分布 iid: 数据同相互不依赖, 训练与测试数据是在
同一分布中采样得到
机器学习基础: 数据特征 → 算法模型 → 衡量标准
机器学习步骤: 确定模型 → 训练模型 → 使用模型

误差: 泛化误差 在实际数据集上的误差
经验误差 在训练集上的误差
泛化: 模型学习到对概念在包处于学习的过程中时模型
没有见过新的样本时的表现
描述泛化好坏: 泛化能力、泛化度

模型评估: 训练集与测试集互斥
留出法 直接把数据集划分为两个互斥子集, 应该将数
据分布的一致性(分层采样), 多次重复划分取
平均值得到误差大小适中 (通常有训练集和验证集)
交叉验证法 把数据集划分为几个互斥子集, 每次有
一个子集作为 k+1 个训练集, 其余 k 个作为测试集
自助法 有放回采样, 从 D 中自助采样 m 个点组成
训练集 D', D-D' 为测试集
性能度量 衡量模型泛化能力
回归任务: 损失函数 MSE $E(f(x)) = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$
分类任务: 损失函数 $E(f(x)) = \frac{1}{n} \sum_{i=1}^n I(f(x_i) \neq y_i)$


ROC TPR = TP / (TP + FN)
FPR = FP / (FP + TN)
PRC precision = TP / (TP + FP)
recall = TP / (TP + FN)



误差: 偏差 bias 模型的期望预测与正确值之差
方差 variance 模型之间 多个拟合模型之间的偏差程度
噪声 noise

回归

线性回归
对于 $y = a_0 + a_1x_1 + a_2x_2 = f(x)$ 目标: 学习最优
方法: 最小化代价函数 $J(w) = \frac{1}{2} \sum_{i=1}^n (a_i - y_i)^2$
法①: 梯度下降 $\theta_j = \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$
法②: single-shot $J(w) = \frac{1}{2} (a^T X - y)^T (a^T X - y)$ 构造
全量 $J(w) = 0$ 得 $X^T X = X^T y$ $\theta = (X^T X)^{-1} X^T y$
几何解释: $X = X_0 + \gamma$ $\gamma = y - y_0$
梯度下降收敛快, 收敛于最优解
但有数量更新和可伸缩性上的问题
正规方程收敛于最优解, 但计算量
大, 且可能导致数值不稳定
岭回归: 在线性回归上添加正则项, 目标函数
 $\min PRSS(\theta) = \frac{1}{2} (y - X\theta)^T (y - X\theta) + \lambda \theta^T \theta$ 使得 $X^T X$ 可逆, λ 的取值使得收敛于
 $\hat{\theta} = (X^T X + \lambda I)^{-1} X^T y$
可以同交叉验证来设定 λ
几何解释: 约束产生阴影可行区域
最小平方范数函数是常数, 一个椭圆
为 X 的 Gaussian 分布, 约束产生阴影可行区域
套索回归 Lasso 把 L_2 改为 L_1
 $\min \sum_{i=1}^n |x_i - y_i|$ s.t. $\sum_{i=1}^n |x_i| \leq t$ $PRSS(\theta) = (y - X\theta)^T (y - X\theta) + \lambda |\theta|_1$
 λ 控制正则化程度 $\theta = 0$ 稀疏
几何解释 同岭, 但约束大多在坐标轴上
OLS Solution



监督 KNN 分类模型


对某个样本点, 计算它与其他所有样本问题, 再进行排
序, 找到其 k 个最近邻, 并把它归入该类的多数类
衡量距离: $L_p = (\sum_{i=1}^n |x_i - y_i|^p)^{1/p}$ 常取 $p=1, 2, \infty$
贝叶斯 先验 $P(x)$ 后验 $P(y|x)$ 似然 $P(x|y)$
 θ 是数据类别, 相似性 θ 是模型参数, 如高斯分布
 $P(y|x) = P(y|x_1, x_2, \dots, x_n) / P(x)$ 机器学习, 通常用似然函数
先验提升, 决策边界向另一边移动
朴素贝叶斯: 每个特征相互独立
贝叶斯决策理论: 自然状态 ω
可能得损失 $\lambda(\omega|x)$
最小化 $R(\omega|x) = \sum_{i=1}^n \lambda(\omega|x_i) P(y_i|x)$
若 $\frac{P(y_1|x)}{P(y_2|x)} > \frac{\lambda_2 - \lambda_1}{\lambda_1 - \lambda_2}$ 则用动作 α_1 , 否则为 α_2
极大似然估计 目标: $\max P(D|\theta) = \prod_{i=1}^n P(x_i|\theta)$
记 $L(\theta) = -\ln P(D|\theta)$ 并令 $\nabla L = 0$
使 μ 未知, 对 μ 的估计以似然满足
 $\sum_{i=1}^n (x_i - \mu) = 0$ $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$

决策树

数据样本从根节点, 根据分支条件下
每个节点收敛到它的所有数据样本
要学习每个节点的判定条件 (阈值)
训练 $H(Y) = -\sum_{i=1}^n P(Y=y_i) \log_2 P(Y=y_i)$
条件熵 $H(Y|X) = -\sum_{i=1}^n P(X=x_i) \sum_{j=1}^n P(Y=y_j|X=x_i) \log_2 P(Y=y_j|X=x_i)$
信息增益 $IG(X) = H(Y) - H(Y|X)$
集成学习 因为单个的判定分类能力不足且训练数据不够
Bootstrap 从大小 n 的数据集
D 中抽取 n 数据样本, 随机采样 n 个数
据样本, 并对每个样本做一定数据操作
Bagging 通过 bootstrap 方式采样训练
集合及训练得到一个分类器
随机森林 用集成学习得到很多决
策树, 并合成




线性分类器 $y = f(w \cdot x + b)$ 用超平面划分数据点
目标: 得到一组或几组好的 w 和 b
损失函数 $L(w, b) = -\sum_{i=1}^n (w \cdot x_i + b)$ 几何意义: 超平面
但不加约束, 则会使 w 与 b 无穷大 故引入正
则化 $\|w\|_2^2$ 或 $\|w\|_1$, 才比较合理
另一种思路: 映射到特征空间, 其中同类点近异类点远
均值 $\mu = \frac{1}{n} \sum_{i=1}^n x_i$ (一次数据有 $N+1$ 维)
类内距 $d_w = \frac{1}{n} \sum_{i=1}^n |w \cdot x_i - w \cdot \mu|$ (假设分 2 类)
类间距 $d_b = \sum_{i=1}^n |w \cdot x_i - w \cdot \mu|$ (假设分 2 类)
LDA 目标: $\max d_b^2 / d_w^2$
 $d_b^2 = W^T \Sigma_b W$ $d_w^2 = W^T \Sigma_w W$
记 $d_b^2 = W^T \Sigma_b W$ $d_w^2 = W^T \Sigma_w W$
 $J(w) = W^T \Sigma_b W / W^T \Sigma_w W$
转化为了特征分解问题, 最佳的 w 即为最大的
特征值所对应的特征向量, $\Sigma_b \Sigma_w$ 是特征值分解矩阵
数据降维成功后再开始分类 (K 近邻)
可通过多组几个 w (第二次, 第三次) 来控制数据降维
到几维, 以保留更多信息用于分类
多类 LDA 类内散度矩阵 $S_w = \sum_{i=1}^n N_j (x_j - \mu_j)(x_j - \mu_j)^T$
类间 $S_b = \sum_{i=1}^n N_j (x_j - \mu)(x_j - \mu)^T$
 μ 是所有数据样本的中心
定义全局散度矩阵 $S_T = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T = S_w + S_b$



SVM 支持向量机

表示在超平面两侧
 $|w \cdot x_i + b| \geq 0$ for $d_i = +1$
 $|w \cdot x_i + b| < 0$ for $d_i = -1$
 $r \propto |w|$
因为任意向量可做分解
 $x = x_p + r \frac{(w \cdot x_p)}{\|w\|}$
又: $g(x_p) = w \cdot x_p + b = 0$ (在平面上)
 $\therefore g(x) = w \cdot (x_p + r \frac{(w \cdot x_p)}{\|w\|}) + b$
 $= r \frac{(w \cdot w \cdot x_p)}{\|w\|} = r \|w\|$
 $= r$
SVM 问题转化为优化问题
 $\min_{w, b} \frac{1}{2} \|w\|^2$
s.t. $d_i (w \cdot x_i + b) \geq 1$ 保证数据不在沟道内
有 n 个数据点就有 n 个约束条件
to optimize from constraint
Lagrangian 函数 $L(x, y, \alpha) = f(x, y) - \alpha (g(x, y) - C)$
KKT 条件 $\frac{\partial L}{\partial w} = 0$ $\frac{\partial L}{\partial b} = 0$
 $g(x) - C = 0$ $\alpha \geq 0$
 $\alpha (g(x) - C) = 0$
对偶问题 拉格朗日乘子 α_i
 $\max Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j (x_i \cdot x_j)$
s.t. $\sum_{i=1}^n \alpha_i d_i = 0$ 保持正负平衡
 $\alpha_i \geq 0$
求出 α 后, 由 $w = \sum_{i=1}^n \alpha_i d_i x_i$ 求出 w , 取一支持向量 x_i
由 $w \cdot x_i + b = 1$ 求出 b
对线性不可分数据
1. 放宽约束, 松弛条件
 $d_i (w \cdot x_i + b) \geq 1 - \xi_i$ $\xi_i \geq 0$
目标: $\min \sum_{i=1}^n (w \cdot x_i + b) + C \sum_{i=1}^n \xi_i$
C 用以调节 $\sum_{i=1}^n (w \cdot x_i + b)$ 和 $\sum_{i=1}^n \xi_i$ 的相对, 使二者
在同一数量级上
选个 C : 10^3 开始, 每次 $\times 10$ 调整
新对偶问题: $\min Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j (x_i \cdot x_j)$
s.t. $\sum_{i=1}^n \alpha_i d_i = 0$ $0 \leq \alpha_i \leq C$
2. 数据升维
升维函数 ϕ 从非线性
且特征空间维度是无穷大才行
 $g(x) = w \cdot \phi(x) + b = 0$ 为新的超平面
升维后问题形式不变, 但 ϕ 没有 $\phi(x)$ 即可
Kernel $K(x_i, x_j) = K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j) = \phi(x_i) \cdot \phi(x_j)$
Gram 矩阵
Mercer's Condition
 $K = \begin{bmatrix} K(x_1, x_1) & \dots & K(x_1, x_n) \\ \vdots & \ddots & \vdots \\ K(x_n, x_1) & \dots & K(x_n, x_n) \end{bmatrix} \in \mathbb{R}^{n \times n}$




PCA 线性数据降维 保留 Variance
x 有原特征向量, $y = W^T x$ 为降维后的特征, 希望降
维后在误差方差最小引入主成分 $y = W^T x$
 $E = X - X_0 = X - W W^T X$
 $\|E\|^2 = X^T X - X^T W W^T X$ 由正交性 $W^T W = I$
 $E[E^T] = E[X^T X] - E[(X^T W)(W^T X)] = E[X^T X] - W^T C_X W$
协方差矩阵 $C_X = \frac{1}{n} (X^T X + \dots + X_n X_n^T)$
记 $J = \frac{W^T C_X W}{W^T W}$
 $\frac{\partial J}{\partial W} = 0$ 可得 $0 = \frac{2 C_X W}{W^T W} - \frac{[W^T C_X W]}{W^T W} \cdot \frac{2 W}{W^T W}$
要让特征值 J 最大
几何意义 W 为旋转轴, W 是其共轭, 故大轴...
找到一个线性映射方向, 使映射后得到数据维度
向量分布最分散最大; 协方差矩阵的特征方向即为最
佳映射方向; 映射到 0 , 方向得到最大 Variance 以及最小
误差方差

MDS 多维缩放

目标: $(\sum_{i,j=1}^n \|x_i - x_j\| - d_{ij})^2$ 降维后距离减去降维前距离
 $\sum_{i,j=1}^n (\|x_i - x_j\| - d_{ij})^2 = \sum_{i,j=1}^n (\|x_i - x_j\|^2 - 2 d_{ij} \|x_i - x_j\| + d_{ij}^2)$
 $T = U U^T = U A^T A^T U = X X^T$ 对 T 分解可得降维矩阵
特征值分解, 也是谱分析
ISOMAP 非线性数据降维使用 geodesic 距离
算法有 3 步
1. 构建邻接图, 可以用 K 近邻 或 E 内连接
2. 用 Floyd 求 Dijkstra 算出每两个点间最短 geodesic 距离
3. 用 MDS 方法解出低维数据降维集 T 从降维
LLE 局部线性嵌入
认为每个数据点和它邻居们处在同一线性
的小块上可被其邻居们线性重建 $x_i = \sum_{j=1}^n W_{ij} x_j$
称 W 为重建系数 $\sum_{j=1}^n W_{ij} = 1$
底空间重建误差 $e(W) = \sum_{i=1}^n \|x_i - \sum_{j=1}^n W_{ij} x_j\|^2$
高空间: $\phi(x_i) = \sum_{j=1}^n W_{ij} \phi(x_j)$
从局部线性关系或低维空间的非线性流形
LLE 与 ISOMAP 解没有显式映射函数

确定初始分组后, 不断将样本数据从一组换到另
一组, 使损失函数最小即可
从 1 被分到 2 后
 $J_2^* = J_2 + \frac{\alpha}{n_2} \|x_2 - m_2\|^2$ $J_2^* = J_2 - \frac{\alpha}{n_2} \|x_2 - m_2\|^2$
每次只迭代一个 x 值, 或迭代批量迭代, 批量到候
就是 K-Means 每次所有点都要迭代
K-Means 初始值敏感, 变量 $\{u_i\}$ 和聚类中心 $\{u_i, m_1, \dots, m_k\}$
 u_i 表示 x 属于第 i 类, 则为 1 , 否则为 0
E-Step 固定聚类中心 u_i 把每个点归到最近中心
保证 $J_2^{(old)} \geq J_2^{(new)}$
M-Step 重新计算中心
保证 $J_2^{(old)} \geq J_2^{(new)}$
初始化与迭代收敛都是问题
收敛损失 是向下而上的方法
选取距离最近的点为一类, 用 Huffman 树的构造
好处: 只算一次即可灵活选取距离最近的数目
高斯混合模型 给出每个点属于每个簇的概率
混合高斯分布 $p(x) = \sum_{i=1}^n p_i(x) p(x) = \sum_{i=1}^n \pi_i N(x | \mu_i, \Sigma_i)$
即 n 个高斯分布之和, 每个高斯分布, 且 $\sum_{i=1}^n \pi_i = 1$
目标: $\max_{\pi, \mu, \Sigma} \prod_{i=1}^n P(x_i | \theta)$
先验概率: 每个簇的先验概率分布
似然: 对每个数据, 属于某一簇的概率
损失函数 $L(\theta) = -\sum_{i=1}^n \log p(x_i | \theta) = -\sum_{i=1}^n \log (\sum_{j=1}^n \pi_j N(x_i | \mu_j, \Sigma_j))$
 $\theta = 0$ 种 $\mu = \sum_{i=1}^n \pi_i x_i$ $\Sigma = \sum_{i=1}^n \pi_i (x_i - \mu)(x_i - \mu)^T$
数据 0 种 $\Sigma = \sum_{i=1}^n \pi_i (x_i - \mu)(x_i - \mu)^T$
每个簇引入一个 k 维向量 $z_i \in \{0, 1\}$, $\sum_{i=1}^n z_i = 1$
 $P(z_i = 1) = \pi_i$ 且 $P(z_i = 1 | x) = \frac{\pi_i N(x | \mu_i, \Sigma_i)}{\sum_{j=1}^n \pi_j N(x | \mu_j, \Sigma_j)}$
Expectation Maximization 算法
相似性度量 $T(x_i) = \sum_{j=1}^n \pi_j N(x_i | \mu_j, \Sigma_j)$
E-Step 固定参数 重新计算 $T(x_i) = \frac{\pi_i N(x_i | \mu_i, \Sigma_i)}{\sum_{j=1}^n \pi_j N(x_i | \mu_j, \Sigma_j)}$
M-Step 固定参数 重新计算 $\mu_i = \sum_{j=1}^n T(x_j) x_j$ $\Sigma_i = \sum_{j=1}^n T(x_j) (x_j - \mu_i)(x_j - \mu_i)^T$
 $\pi_i = \sum_{j=1}^n T(x_j)$ $\Sigma_i = N_i / N$
GMN 是所有的 K-Means, $T(x_i) = 1$ 时这称为 K-Means



谱聚类

KM 与 GMM 都要找中心, 谱聚类则是找邻居
把聚类问题转化为图论问题
计算每对点内两两距离, 构造相似矩阵 $S = [s_{ij}]$
欧式 $s_{ij} = \|x_i - x_j\|^2$ 高斯 $s_{ij} = e^{-\|x_i - x_j\|^2 / 2\sigma^2}$
再构造邻接矩阵 W $W_{ij} = 1$ if $s_{ij} > \epsilon$
距离小于 ϵ 才是邻居
也可以空连接
边 W_{ij}
度 $d_i = \sum_{j=1}^n W_{ij}$
子图邻接 $A = \sum_{i,j=1}^n d_i$
到 $Cut(A, B) = \sum_{i \in A, j \in B} W_{ij}$
所给 $D = \sum_{i,j=1}^n d_i$
Laplacian 矩阵 $L = D - W$
定义 $N \times 1$ 特征向量 $x = [x_1, x_2, \dots, x_N]^T$ $x_i = 1$ 表示第 i 个
节点属于子图 A, 为 0 则不属于
则 $Cut(A, B) = x^T D x - x^T W x = x^T L x$
新目标: 找到最小值 x s.t. $x^T D x = E$
若 $\lambda = \lambda D x$
若一个数据有多维度 x , 则可线性组合成一个 x
视 x 为低维做 K-Means 在新构造空间中数据更可
线性组合
谱聚类本质上大概率是空沟转成沟的过程

PCA 线性数据降维

保留 Variance
x 有原特征向量, $y = W^T x$ 为降维后的特征, 希望降
维后在误差方差最小引入主成分 $y = W^T x$
 $E = X - X_0 = X - W W^T X$
 $\|E\|^2 = X^T X - X^T W W^T X$ 由正交性 $W^T W = I$
 $E[E^T] = E[X^T X] - E[(X^T W)(W^T X)] = E[X^T X] - W^T C_X W$
协方差矩阵 $C_X = \frac{1}{n} (X^T X + \dots + X_n X_n^T)$
记 $J = \frac{W^T C_X W}{W^T W}$
 $\frac{\partial J}{\partial W} = 0$ 可得 $0 = \frac{2 C_X W}{W^T W} - \frac{[W^T C_X W]}{W^T W} \cdot \frac{2 W}{W^T W}$
要让特征值 J 最大
几何意义 W 为旋转轴, W 是其共轭, 故大轴...
找到一个线性映射方向, 使映射后得到数据维度
向量分布最分散最大; 协方差矩阵的特征方向即为最
佳映射方向; 映射到 0 , 方向得到最大 Variance 以及最小
误差方差