

# ML Project：三维物体重建

王凯灵 521030910356    卜家梓 521030910395    张致远 521030910377

## Abstract

本报告是 AI2612 课程《机器学习工程实践》选题三“三维物体生成与重建”的项目实验报告。项目小组成员为王凯灵、卜家梓、张致远。

本组分配到的重建物体类型为“家具”。在数据收集阶段,我们通过自主编写的基于 Edgedriver 的爬虫脚本,从 Sketchfab 网站上爬取了桌椅、浴缸、衣柜、台灯等十余种共 2000+ 份 3D 家具模型数据,经过手工遴选,选出了 1300+ 份优质模型数据。该爬虫开源于此[处](#)。由于原项目提供了大型三维模型数据集 Objaverse-XL 用于训练。为了充分利用现有工作,我们开发了无监督的零样本无标签三维模型分类方法用于直接从 Objaverse-XL 中获取数据,该工具开源于此[Loping151/FAFO](#)。为构建“单视图-模型”数据对,我们使用 blender 软件获取 3D 模型在不同视角下的二维视图,再从中挑选出合适的视角组成数据对。在此过程中,我们还使用了自主编写的类 git 自动化数据集同步工具实现多人协作筛选,配套了完整的[数据处理工具链](#)。本组主要采用了课程中演示的 One-2-3-45 方法进行多视图生成和模型生成。我们完成了对于该方法解决的问题与运行性能的分析,并发现和改正了官方代码中的一处[Bug](#)。我们使用了 Clip 相似度和 CD (Chamfer Distance) 对该方法生成结果进行评价。在评价过程中,我们解决了 Blender 软件存在的缺陷并向官方发送了汇报邮件。此外,我们还尝试了其他单视图重建方法 SyncDreamer 与 Wonder3D,并于 One-2-3-45 进行比较。最后,我们分析了多视角一致性的改进策略,对最新工作进行综述。

本次项目的各个阶段的完整数据、相关工具链与批处理脚本于此[处](#)查看和下载(下载提供至 2024 年 2 月)。

在该项目中,本小组完成了加分项中的**难点 4**以及**易项 1**。

## 1. 任务分析与相关工作

### 1.1. 3D 生成式任务

3D 生成式任务主要包含文字-3D 生成和单视图-3D 生成[\[26\]](#)。该任务的典型方法主要分为两个步骤:文字/单视图的多视图生成、多视图的三维重建。此前也有基于 GAN 的生成方法[\[30\]](#)。近年来,使用 Diffusion 技术方法逐渐流行,越来越多的工作使用 DALL-E 等进行多视图生成[\[15, 14, 21, 29, 11, 10, 12, 25\]](#)。同时,随着 NeRF[\[18\]](#)方法的火热,许多方法使用基于 NeRF 的重建模块。近期,一些新的工作也开始采用 3D 高斯方法进行重建[\[1, 27, 34, 8, 9, 2, 13, 28\]](#),相比于 NeRF,基于高斯的方法普遍具有拟合能力更强,优化速度更快。

### 1.2. 任务难点与解决思路

3D 生成任务的核心问题在于解决一致性问题。该问题有两种主要解决思路:一是在生成多视角图像时保证 2D 生成模型生成一致性更好的图像,二是通过减少多视角图像数量避免一致性冲突,转而在重建模块中进行稀疏视角重建[\[31, 33, 23, 20, 32\]](#)。本文 One2-3-45 还采用了第三种方法,我们将在后文中分析介绍。

### 1.3. 本文内容

在第2节,我们将介绍我们在第一阶段原始数据获取思路与方法,以及数据来源,包括 Sketchfab 和 ObjaverseXL。在3节中,我们进一步展开我们在生成为了生成模型对数据进行的进一步处理,以及生成时的方法细节。在4节中,我们介绍了生成结果与指标评价细节,包含了生成结果位姿矫正,Blender 渲染问题与解决。在5节中,我们回顾 One-2-3-45 使用的 Zero123,并将其与其他多视图生成效果进行对比,完成了**难点 4**。在6节中,

我们进一步分析了其他工作解决多视图一致性的方法，简单综述了一些近期工作，完成了**易项 1**。关于**易项 1**的理解还在全文其他部分提及。

## 2. 数据收集阶段

### 2.1. 3D 模型数据爬取

经过对项目指导给出的参考网站及其他 3D 建模网站的调研，我们发现 Sketchfab 网站含有品类繁多的家具模型数据，决定以它作为数据源。

我们最初选择了 .glTF 格式作为下载的数据格式。相比于其他常见的 3D 格式，.glTF 格式具有开源、通用性强、可内嵌其他格式、储存信息完整可编辑等优势。在后续工作中，我们在工具链中包含了 .glTF、.glb、.ply 的相互转换工具和每个格式相应的渲染脚本。

为了能从 Sketchfab 的网页端批量获取模型数据，我们采用 python-selenium 进行 Web 自动化，调用 Webdriver（我们选用 Edgedriver）在后台模拟 agent 与浏览器进行交互，从而实现自动化的下载任务。

针对 Sketchfab 的网站结构，我们设计的爬虫脚本具有如下特点：

1. **账号接口**：经测试，同一账号在 Sketchfab 网站的每日下载量上限约为 150 份，为提高数据日产量，脚本提供了便捷的账号切换接口和自动登录功能。
2. **付费验证**：Sketchfab 网站含有一些需付费使用的模型数据，它们相较于免费模型在下载流程上增加了付费环节，这会增加脚本处理的难度。因此，在进入下载流程前，脚本会先对数据是否需要付费进行验证，并排除付费数据，保证流程的统一。
3. **自动翻页**：网页中单面能够容纳的数据量是有限的，在下载完当前页面的数据后，脚本实现了自动翻页功能，以继续获取数据。
4. **日志记录**：为防止重复下载数据以及下载过程中网络波动造成的中断，脚本维护了一份

已下载数据的日志文件。当脚本遍历到日志中已有的数据时，它不会被脚本所采集。

已开源于[此处](#)。

通过运行爬虫脚本，我们从 Sketchfab 网站上采集了 2000+ 份原始家具模型数据，涵盖桌、椅、衣柜、橱柜、灯具、浴缸、马桶、水龙头、扫把等多种家具类别，数据全面且均衡。

### 2.2. ObjaverseXL 模型获取

ObjaverseXL[3] 是 Zero123[12] 使用的训练数据集 [4] 的扩大版本，截至 0.15.0 版本已经包含超过一千万的 3D 模型数据。该数据集实际上提供了一个大型的 3D 模型数据库，记录每个模型的开源地址。然而，ObjaverseXL 除了模型的名称以外，没有提供模型所属类别信息，使得该数据集难以用于 3D 分割、3D 分类等热门任务。为了解决这个问题，同时获取本项目所需数据，小组成员创造性地尝试使用 Clip、Blip 等图像工具，对 3D 模型进行无监督、零样本、无标签的目标类检索与下载。第一步，下载每个 3D 模型，调用 blender 进行渲染。第二步，使用 Blip[7, 6] 和 Clip[22] 分析获得的单视图或多视图。第三步，将模型归入所属类或删除。

其中，利用 Blip 的方式更为直接，由于 Blip 模型支持 image to text 能力，直接进行 image to text 与目标类文字比较即可。利用 Clip 的方式需要仔细设计。利用 Clip 可以得到图像与文字的相似度，但不同图文对的相似度尺度不同，无法通过阈值进行分类。同时，目标分类不已知全部标签，无法通过逐个比较的方法进行分类。此时，受到经典哲学命题“人是不是个东西”启发，由于 Clip 学习到几乎任意物体与"Object"具有弱关联，可以作为分类基准，例如一张狗的图像应被判断为“More a dog than an object, but more an object than a person”，故就此进行实验，样例如图1，结果如表1。可见这种分类策略近乎完美的完成了零样本无标签分类任务。然而由于 Objaverse 本身提供的工具下载速度过慢，数据质量不如来自 Sketchfab 的数据，最终仅将本工具作为 demo 展示。




图 1: Clip 实验选择的图片

表 1: Clip 实验结果

| gt/score | Chair       | Dog         | Lego        | Desktop     | Person      | Object |
|----------|-------------|-------------|-------------|-------------|-------------|--------|
| Chair    | <b>31.5</b> | 25.2        | 25.5        | 22.9        | 24.9        | 29.6   |
| Dog      | 20.1        | <b>32.8</b> | 23.8        | 22.2        | 25.7        | 25.6   |
| Lego     | 25.3        | 29.2        | <b>33.5</b> | 28.1        | 29.2        | 31.5   |
| Desktop  | 22.4        | 25.1        | 28.0        | <b>30.0</b> | 26.3        | 28.9   |
| Person   | 27.4        | 30.9        | 26.7        | 30.6        | <b>35.5</b> | 31.5   |

### 2.3. 其他数据来源

我们本希望从知名作者 Alex Yu[35] 的LUMA AI获取基于 Nerf[18] 的 text to 3D 结果, 然而, 看到了\* 实际结果 \*后, 我们很快放弃了这个想法。

## 3. 数据处理与模型生成

### 3.1. One-2-3-45 方法简介

One-2-3-45[11] 是一种根据单张视图进行三维重建的新颖方法, 不同于现有的诸多基于神经辐射场 [18, 19, 5, 35] 优化的单视图重建手段, One-2-3-45 先利用 2D 扩散模型 Zero123[12] 生成多视角图像, 然后基于改进的 SparseNeuS[16] 使用多视图来重建 3D 模型。

Zero123 是一种基于视角控制的 2D 扩散生成模型。通过对 Stable Diffusion 模型 [24] 的微调, Zero123 实现了给定一个物体的单张 RGB 图像和一个相对相机变换, 预测在变换后的相机视角下该物体对应图像的功能。本文借助 Zero123 根据单视图生成多视角图像后, 结合新提出的基于最小化重投影误差的仰角估计模块推断输入图像的仰角, 以优化一致性问题。

为了解决稀疏视角重建问题, One-2-3-45 使用基于 SparseNeuS[16] 的重建方法, 结合了 3D CNN 与体素投影方法编码 2D 图像特征, 使用轻量的 MLP 预测模型的 SDF 表达和纹理, 然后通

过 marching cube 方法提取 mesh 模型。

One-2-3-45 提出的方法摆脱了耗时的优化过程, 将生成一个高质量 3D 纹理网格的时间压缩到了 45 秒内, 具有极高的效率。

### 3.2. 数据处理与管理工具

#### 3.2.1. 多阶段数据清洗

我们的数据筛选工作分为以下两个阶段:

1. 在采集完原始数据后, 我们对其进行了第一遍手工筛选, 这次筛选的主要目的是去除**不合规的数据**, 例如类别错误的数据、低质量的数据、复杂的多模型(摆放复杂, 不适用于单视图重建任务)的数据等。为了加快筛选速度, 我们对模型进行了简单渲染, 以排除明显不符合要求的数据。经过此次筛选, 我们获得了 1300+ 份较优质的家具模型数据。我们将该数据作为**第一阶段的原始数据提交**。
2. 为了得到**最合适的渲染图**, 并去除**难以从单视图获取足够信息的数据**, 例如结构严重非对称的数据、遮挡严重的数据、含有过于复杂纹理的数据、差异明显的离群数据等, 我们对模型进行了多视图渲染, 进行了二次筛选。由于模型的初始朝向不一且不同类别物体适宜的渲染角度不同, 固定的一个渲染角度无法较好的渲染出全部模型。对于每个 3D 模型, 我们都从 8 个角度分别进行渲染: 仰角  $\theta$  分别为  $\frac{\pi}{3}, \frac{\pi}{2}$ , 方位角  $\phi$  分别为  $0, \frac{\pi}{2}, \pi, \frac{3\pi}{2}$ 。人工找出最适合进行 3D 重建的一张视图并保存。若不存在合适的角度, 则舍弃此模型。经过此次筛选, 我们最终得到了 1000+ 份精选的单视图-模型数据对, 用于网络的测评。

#### 3.2.2. 数据管理工具

由于筛选工作涉及大量的小文件且数据总体积庞大。为了更好的实现在统一数据集上的多人协作, 我们受到 git 和 apt 等工具的启发, 开发了针对数据集的类 git 同步工具 DB-Sync。为

了同时兼容三人使用的 MacOS, Windows 以及 Ubuntu 系统, 工具主要使用 Python 编写。我们自数据清洗的第二阶段开始采用该工具。

该工具首先将复杂的 gltf 文件包转为单个的 glb 文件, 并统一使用文件的 sha256 值命名, 以统一长度, 避免重复以及方便批处理。每个用户端初始化时下载完整的原始数据。用户执行 load 操作, 从小组成员的私人公网服务器下载最新的文件列表并在本地删除相应文件。save 操作将本地的文件列表与云端列表取交集后更新。工具还支持自动检查单视图-模型文件对应关系, 发布数据更新等操作。详见[使用说明](#), 由于鉴权问题, 我们将不会轻易开源涉及公网云的部分。每个阶段(包括后续阶段)的数据文件可于[此处](#)下载(下载提供至 2024 年 2 月)。

### 3.3. 模型的部署与运行

由于部分成员在集群上不具有 sudo 权限, 导致无法安装环境所需系统库, 我们主要在小组成员的本地服务器上部署, 平台环境为 RTX 4090 (CUDA 11.8) 的 Linux (Ubuntu 22.04) 系统, torch=2.0.1, Blender=4.0.1。

在将推理代码改为批处理时, 需要特别注意将加载的模型设为全局变量, 以避免反复加载与释放造成大量的时间开销。我们将输入的单视图渲染为  $512 \times 512$  分辨率, 两个阶段图像生成和位姿估计尤为耗时, Zero123 采样得到两阶段  $4 * n$  共 32 张  $256 \times 256$  的图像共需 20 秒左右, 前向预测 SDF 表达所需 10 秒以内, 加上密集 io 耗时, 单次推理平均时长为 30.1 秒。该阶段实际重建模型共 1026 份, 其中 24 份生成了多视角图像后, 在经过 One-2-3-45 的原创位姿矫正模块时失败, 最终成功重建 1002 份。显存占用开销主要在 Zero123 模型推理, 实际占用  $\sim 11G$  显存, 正好足够在一张没有运行图形界面的 RTX 2080Ti 上运行。使用上述配置实际总连续运行时间约 8 小时, 使用 RTX 2080Ti 双卡并行运行时间约 7 小时(已排除加载时间, 因为使用 2080Ti 运行需要将用完的模型移动到 CPU 腾出显存)。

关于失败的位姿估计模块, 检查代码发现已

经做了异常处理, 但是由于代码疏忽, 实际失败的情况没有正确抛出异常, 导致代码在异常处理之外报错, 不能完成生成。已在原 repo 汇报[这个问题](#), 并已在官方仓库最新的 commit 中改正。

借此机会, 我们分析了代码具体实现。我们注意到除了位姿估计模块含有遍历操作复杂度较高外, 代码实现十分注重运行效率。代码使用 TCNN 预测 SDF 和体渲染预测 rgb 的 MLP, 可以达到远超 torch 实现的性能。

## 4. 结果评价与分析

我们使用 Clip 相似度和 3D 模型的 CD (Chamfer Distance) 作为指标。

### 4.1. 位姿一致性修正

为了保证渲染设置完全相同, 我们需要在渲染前将真值模型与重建模型旋转为同一位姿。由于重建模型质量总体不高, 使用估计方法预计不能取得良好效果。由于 One-2-3-45 在使用 Zero123 时会将输入图像旋转单位矩阵后生成一个视图, 而第二阶段的仰角估计模块会利用最小化重投影误差重新估计这个视图的位姿, 实际上这个估计的位姿就是在该方法下对输入图像位姿的最佳估计。

但是, 由于 Zero123、blender、One-2-3-45 保存点云使用的 trimesh、meshlab 的 ply 系、meshlab 的 glb 系百花齐放, 百家争鸣, 囊括了左手系、右手系、球系等多个种类的坐标系, 我们需要通过一系列数学计算, 才能正确的旋转点云。

在[3.2.1](#)中, 我们提到我们使用确定的视角渲染图像并挑选。每张挑选图像的视角元数据在同步工具中有记录。记视角仰角  $\theta$ , 方位角  $\phi$ 。渲染过程中定义的视角事实上是观察位置, 即相机光轴朝向的相反。定义物体几何中心为世界坐标系原点, 世界坐标轴  $\mathbf{x}_w, \mathbf{y}_w, \mathbf{z}_w$  按右手系, 相机保持正对物体, 光轴始终经过原点, 初始时朝向  $-\mathbf{x}_w$  方向。初始时相机坐标系对世界坐标系旋转矩阵为单位阵。由于我们只关心物体的旋转情况, 可以忽略向量长度因子, 统一视为归一化的。通过  $\theta, \phi$

可以计算得到相机位置的方向向量为

$$\mathbf{p}_c = [\sin \phi \cos \theta, \sin \phi \cos \theta, \sin \phi]^T \quad (1)$$

如此，单视图渲染相机的光轴方向为  $-\mathbf{x}_c = -\mathbf{p}_c$ 。则  $\mathbf{R}_{c2w}$  为  $[\mathbf{x}_c, \mathbf{y}_c, \mathbf{z}_c]^T$ ，其中

$$\begin{cases} \mathbf{y}_c = \mathbf{z}_w \times \mathbf{x}_c \\ \mathbf{z}_c = \mathbf{x}_c \times \mathbf{y}_c \end{cases} \quad (2)$$

我们希望旋转物体，物体相对相机的旋转

$$\mathbf{R}_{render} = \mathbf{R}_{c2w}^{-1} = \mathbf{R}_{c2w}^T \quad (3)$$

需要将渲染时定义的坐标系转换到 One-2-3-45 使用 trimesh 保存点云时使用的坐标系，具体而言：

$$\begin{cases} \mathbf{x}_c \rightarrow \mathbf{y}'_c \\ \mathbf{y}_c \rightarrow \mathbf{z}'_c \\ \mathbf{z}_c \rightarrow \mathbf{x}'_c \end{cases}, \text{ 即 } \mathbf{R}'_{render} = \mathbf{T}_{yzx} \mathbf{R}_{render} \quad (4)$$

其中

$$\mathbf{T}_{yzx} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \quad (5)$$

输入图像对于重建物体具有估计得到的位姿  $P$ ，记其中旋转矩阵为  $\mathbf{R}_P$ 。类似地，有

$$\mathbf{R}_{recon} = (\mathbf{R}_P^{-1})^{-1} = \mathbf{R}_P \quad (6)$$

最后，One-2-3-45 使用 trimesh 将点云保存为 glb 时，使用了左手系，故还需应用  $\mathbf{T}_{-y}$ （与  $\mathbf{T}_{yzx}$  定义类似）。完整的对齐旋转矩阵为：

$$\begin{aligned} \mathbf{R} &= \mathbf{T}_{-y} \mathbf{R}_{recon} \mathbf{R}'_{render} \\ &= \mathbf{R}_P [\mathbf{y}_c, -\mathbf{z}_c, \mathbf{x}_c]^T \end{aligned} \quad (7)$$

图2展示了典型的对齐结果，可见对齐十分准确，为后续评价工作提供了强有力的支撑。

在 meshlab 中，同一模型的 glb 系和 ply 系坐标还存在绕  $y$  轴  $90^\circ$  的差异，即使 glb 中内嵌的 mesh 就是 ply 表示。



图 2: 模型对齐效果

注：虽然该过程完成了要求中难项的第一条，但实际上该过程是计算点云距离的必须步骤，我们对此表示质疑。我们最终选择了难项 4 作为任务目标。

## 4.2. Clip 相似度测评

上一小节中模型已经对齐，我们重新将真值与重建模型以仰角  $\theta = \frac{\pi}{3}, \frac{\pi}{2}$ ，方位角 12 等分渲染了各 24 张图像。

### 4.2.1. Clip 相似度计算方法

不论是 One-2-3-45 原文 [11] 还是其借鉴指标的 RealFusion[17]，都没有指明具体如何计算 Clip 相似度。一般而言，我们使用余弦相似度进行度量，若两张图片的特征编码为  $\mathbf{a}$  和  $\mathbf{b}$ ：

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \quad (8)$$

余弦距离为  $[-1, 1]$ 。常见的处理是将余弦距离重新归一化到  $[0, 1]$ ，然而，我们使用官方示例的重建图像进行计算，发现相似度均值达到 86.7%，显著高于官方汇报的 78.1%。然而如果不进行归一化，又显著低于官方数值。于是，我们通过直接在群聊中突袭原作者 [10] 的方式确认了，原文的确没有进行  $[0, 1]$  归一化，因为 Clip 余弦相似度一般都为正。总之，通过与作者交流，我们严格保证和官方一致的相似度计算方式。

关于图像背景问题，为了研究图像背景对于 Clip 相似度的影响，我们分别尝试了全黑背景，全白背景，透明背景 (RGBA)，并分别使用  $512 \times 512$  的渲染原图和使用 Bounding Box 切出物体的图像计算，实验结果证明 Clip 对于纯色背景不敏感，误差均值小于 1%（仅第三位小数及以后发生改变）。我们最终采用了 Bounding Box 结合透明背景的图像进行相似度计算。

#### 4.2.2. 渲染异常问题与解决

在初次计算时，我们发现 Clip 相似度的均值达到了 90% 以上，比原文高出过多。查看渲染图像，发现渲染图像纹理丢失，全为白色，故 Clip 相似度极高。显然，渲染时纹理发生了丢失。我们尝试使用 meshlab 查看重建得到的文件，发现不论是 ply 还是 glb 格式都会使 meshlab 直接崩溃。然而，部分在线查看器和 vscode 插件却能正常查看纹理。考虑到重建得到的文件使用 trimesh 进行保存，我们阅读了重建文件的文件头，与 blender 标准的 glb 文件头进行对比，发现 trimesh 只保存了极少信息，缺失了对包括 "materials" 字段等的定义。Blender 等软件很可能依赖这一字段解析 bin 中的纹理。虽然直接在头中添加字段很可能可以解决该问题，我们实际发现并利用了 Blender 软件的一个特性：我们首先导入所需渲染文件，然后导入一个预定义的模型文件。这个后导入的模型需要具有唯一一个纹理。然后立即删除后导入的模型文件，此时，发现可以将后导入模型的材料赋给所需渲染文件，此时 Blender 能够正确找到渲染文件自身的纹理。起初，我们使用初次发现该 Bug 的红色书架文件作为预定义文件。为了排

除书架纹理对其他模型可能造成的影响，我们之后使用了纯红色的方块替代。渲染结果中没有出现异常的红色，可见材质已被正常加载。我们将这一情况通过邮件汇报给了官方。

在渲染时，我们还控制了合适的光照，相机距离等无关变量。

#### 4.2.3. 结果与分析

结果数据如表2。Clip 相似度相较于原文给出数据略微更高。原文中提到，作者发现 Clip 相似度对于物体的纹理比较敏感。本组测试的模型主要为家具，与一般物体相比，家具多为单一颜色，尤其是浴缸，水龙头等，大多为全白，材质多为金属，木板，无花纹或具有重复的纹理，几何结构工整。简单的颜色纹理使得 Clip 相似度更易变高，而真值模型光滑的表面材质也与重建得到的平滑三角 mesh 反射情况更加接近，从而渲染颜色更一致。观察数据发现浴缸，水龙头等白色且没有纹理的模型，Clip 相似度显著高于其他类别。而椅子等结构复杂的物体 Clip 相似度较低。典型的案例如图3，4所示。



图 3: 低相似度典型案例




图 4: 高相似度典型案例

由于结构、颜色和纹理简单的模型占相当比重，我们的相似度高于原文是合理的。

表 2: 评价结果

| Category  | Clip Similarity | Normalized CD |
|-----------|-----------------|---------------|
| Bathtub   | 82.51           | 0.096         |
| Bed       | 81.25           | 0.078         |
| Bookshelf | 81.11           | 0.105         |
| Broom     | 84.50           | 0.137         |
| Chair     | 77.18           | 0.114         |
| Cupboard  | 80.71           | 0.108         |
| Door      | 80.48           | 0.164         |
| Faucet    | 82.42           | 0.100         |
| Lamp      | 81.73           | 0.116         |
| Sofa      | 80.66           | 0.084         |
| Table     | 81.72           | 0.081         |
| Toilet    | 81.13           | 0.092         |
| window    | 79.95           | 0.174         |
| Total     | 80.65           | 0.110         |

#### 4.3. 3D 模型准确性

对于已经对齐的点云，我们对模型进行体素采样而不是要求的表面采样。体积采样可以更好地衡量模型几何形状的重建，尤其体现在重建时将浴缸重建为实心的案例，体积采样可以增大该情况的距离。

我们认为各个方向上的距离应该被均等地度量，所以我们使用了三维的 Bounding Box 将点云缩放至  $1 \times 1$  的单位空间中。我们将真值模型采样的点云染为蓝色，重建模型染为红色，可视化如图5。

设点云  $\mathbf{A}$  和  $\mathbf{B}$ ，Chamfer Distance (CD) 的计算公式如下：

$$CD(\mathbf{A}, \mathbf{B}) = \frac{1}{|\mathbf{A}|} \sum_{\mathbf{a} \in \mathbf{A}} \min_{\mathbf{b} \in \mathbf{B}} \|\mathbf{a} - \mathbf{b}\|^2 + \frac{1}{|\mathbf{B}|} \sum_{\mathbf{b} \in \mathbf{B}} \min_{\mathbf{a} \in \mathbf{A}} \|\mathbf{b} - \mathbf{a}\|^2 \quad (9)$$

重建结果在整个数据集上的 Chamfer Distance 情况如表2所示，均值为 0.110。相比之下，将单位空间的均匀采样  $\Omega \in [0, 1]^3$  绕中心旋转  $\alpha = 30$  度，与旋转前的对应点轨迹距离期望为：

$$\frac{1}{|\Omega|} \iiint_{(x,y,z) \in \Omega} \sqrt{x^2 + y^2} \alpha dx dy dz \quad (10)$$

$\approx 0.131$

可见重建的三维准确性良好。




图 5: CD 点云对齐

## 5. 其他单视图重建方案的对比

### 5.1. Zero123 改进策略回顾与分析

在3.1小节，我们已经介绍了 One-2-3-45[11] 的基本内容。在完成了评价以后回顾，我们认为 One-2-3-45 解决一致性的方法主要有二：

- 位姿估计模块：

本文直接采用 Zero123[12] 作为多视图生成模块，本身可以取得较好的一致。在此基础上，本文观察发现在旋转极小时，Zero123 生成的新视图高度准确，于是使用最小化重投影误差的方法，设计了两阶段的多视图选择过程，估计了更加精准的视图位姿以加强空间上的一致性。

- SDF 重建方法：

本文使用对 SDF 场的估计方法，通过 marching cube 生成三维网格，可能会牺牲质量和重建 PSNR 等指标，但能保证几何上的连续性，不会像使用神经隐式方法，在不一致时会导致支离破碎的重建结果。

接下来，我们会结合以上内容，将本文于其他单视图重建方法进行对比分析。

## 5.2. SyncDreamer

### 5.2.1. 方法简介

SyncDreamer[14] 是一种更新颖的扩散模型, 它同样能够完成基于单视图进行三维重建的任务。

在前文中我们提到, One-2-3-45 方法使用了基于预训练 2D 扩散模型 Stable Diffusion 的 Zero123 来生成物体的多视角图像。然而, 这种方法生成的多视图在几何形状和颜色上难以保持一致性。

针对这个问题, SyncDreamer 提出了一种同步多视图扩散模型, 能够建模多视图图像的联合概率分布, 实现在单个反向过程中生成多视图一致的图像。

相较于 One-2-3-45, SyncDreamer 引入了 3D 感知特征注意机制, 将生成图像的中间状态进行同步, 从而将不同视图下的相同特征关联起来。

### 5.2.2. 模型部署

总体而言, SyncDreamer 在部署算力要求上低于 One-2-3-45, 我们成功在平台环境为单张 RTX 3090 的非 sudo 权限 Linux (Ubuntu 20.04) 集群机器上部署并运行了该代码, torch==2.0.1。

## 5.3. Wonder3D

### 5.3.1. 方法简介

Wonder3D[15] 是一种高效重建**高质量纹理网格**的新方法。

前文提及的 One-2-3-45 和 SyncDreamer 依赖快速网络推理来获得 3D 信息, 这种方法比较快速, 但是重建模型的质量较低, 缺乏 3D 细节。另一方面, 注重几何细节的优化类算法又非常耗时。

Wonder3D 提出了以下的解决方案:

- cross-domain diffusion model: 在生成一组相机位姿对应的多视角图像时, 同时生成能够刻画物体表面真实几何细节的 normal maps 和彩色多视图 color images。
- multi-view cross-domain attention: 类似

SyncDeamer, 利用全局注意力机制, 使多个视角下的图像产生关联, 保持几何形状和颜色上的一致性。

- geometry-aware normal fusion algorithm: 通过优化有向距离场 SDF, 提取显式 3D 几何。这种方法适合于较为稀疏、具有细微差异的多视角生成图优化。

Wonder3D 方法能够在 2 分钟内重建出高质量的纹理网格, 相较于前人的工作而言, 实现了高质量的重建结果、优秀的泛化性能和较高的效率。

### 5.3.2. 模型部署

类似 SyncDreamer, 我们将 Wonder3D 模型部署并运行在平台环境为 RTX 3090 的非 sudo 权限 Linux (Ubuntu 20.04) 集群机器上, torch==2.0.1。

## 5.4. 效果分析及对比

One-2-3-45 和 SyncDreamer、Wonder3D 等方法都是先基于物体的单视图生成不同相机位姿的多视图, 然后再利用生成的多视图进行三维重建, 因此多视图的质量直接决定了重建模型的优劣。我们将三种方法生成的多视图进行横向对比展示, 能够更清晰地反映联合概率分布等方法对多视图几何细节的提升, 如图6所示。

图6展示了两类物体在三种单视图重建方法下得到的多视图, 从左至右依次为物体的正视图、左视图、后视图与右视图; 第一、二行图像分别为 One-2-3-45 和 SyncDreamer 的生成结果, 第三行和第四行图像分别为 Wonder3D 生成的 colored images 和 normal maps。为保证公平性, 三种方法均使用物体的正视图进行 inference。

不难发现, 在我们选择的两个样例中, One-2-3-45 生成的多视图均出现了不同程度的失真。在左图的沙发椅样例中, 它生成了错误的畸变左视图, 与其余三张正确估计的视图有着明显的几何形态差异; 而在右图的橱柜样例中, One-2-3-45 对视图的估计几乎全部错误, 不仅难以组合出正常的家具形状, 颜色上也有较大的区别。这说明



图 6: 不同重建方法生成多视图对比

One-2-3-45 方法利用 Zero123 生成的多视图具有的一致性是有限的, Zero123 能够捕捉物体总体的形状和颜色信息, 但是在细节上有较大的损失, 这对于后续的三维重建环节有着较大的影响。

相较于 One-2-3-45, SyncDreamer 生成的多视图在几何形状和颜色上具有较好的一致性, 这得益于它在生成多视图时采用的联合概率分布。在两个样例上, SyncDreamer 估计的多个视角的确类似从真实物体四周观察得到, 不存在某个视图与其余视图存在显著形状或颜色差异的情况。但是, 在橱柜样例中, SyncDreamer 出现了整体几何形状的错误估计, 将近似长方体的橱柜估计为倾斜的多面体, 这个错误也在它生成的多视图上一致地保留下来。

Wonder3D 使用了跨域扩散模型 (cross-domain diffusion model), 在生成多视角图像 colored images 的同时, 也生成了用于表征物体表面几何细节的 normal maps, 同时跨域注意力机制 (cross-domain attention) 又使得两种表征能够保持较好的一致性约束。在两个样例中, Wonder3D 有着出色的表现, 不仅继承了 SyncDreamer 几何

颜色一致性的优点, 对于物体的真实几何信息也有较好的把握。

总体来说, 高质量的多视图既需要真实的几何细节, 也需要在多个相机位姿下保持几何形状和颜色的一致性, 如何在多视图质量和生成速度上取得平衡, 是后续单视图重建工作值得思考的一个方向。

## 6. 多视角一致性改进与相关工作综述

在本文的讨论中, 多视角一致性是由 2D 生成模型提供的。以 Zero123[12] 为例, 一致性是在训练 2D 模型是添加约束实现的, 在数学上, 体现为从一般 2D 生成模型的从完整图像空间映射到可理解图像空间, 变为映射到有规律的可理解图像集合的空间。虽然诸如 Control Net, Lora 的工作已经向我们展现了 2D 生成模型的强大能力和潜力, 但我们仍然无法随心所欲地控制生成目标。一致性只要产生细微偏移, 就可能在 Nerf 类方法重建时出现三头六臂的 Janus problem。

## 6.1. 改进的一般思路

抛开一切现有方法，从一个 Stable Diffusion 开始，我们在未进行文献调研时，提出了自己的朴素想法。Stable Diffusion 的原始预训练版本几乎不具有任何视角转移一致性能力，而且带有背景。基于预训练模型的修改是极其困难的，应当重新训练模型并调整模型结构。

- 训练数据

由于难以想象高质量的环境多视角 2D 图像数据集的存在，较为简单的方法是通过三维数据集渲染得到。然而，我们在收集数据时以及注意到了一个问题，就是数据集中模型的初始位姿是极难定义的，如果一张椅子初始时的位姿是翘起的，产生的图像-位姿数据无疑会使模型产生误解。参考著名分割模型 SAM 的训练，高质量的正位姿三维数据无疑能直接带来一致性的性能突破。

- 模型结构

要提高一组图像的一致性，如果我们使用传统 CV 的观点看待这个问题，应该在这组图像集上进行联合优化，不断 refine 相邻视角的一致关系。而在 Diffusion 模型中，我们可以在每个 step 中执行这个 refine 过程。换言之，可以同步生成多视角的图像。假设 Diffusion 模型的初始输入噪声改为已经绑定一致点的模板图形，如果将 CG 知识先验带入每个 step 的迭代，就有可能生成高度一致的图像。

此外，相关的优化函数和 Diffusion 方程的改进也应能带来效果的提升。

## 7. 近期方法综述

在上一节中，我们已经介绍了 SyncDreamer, Wonder3D 两种方法提出的改进策略，前者的思路是同步扩散，后者是直接生成空间几何信息。同一时期，以 GaussianDiffusion[8] 为代表的一系列方法利用 3DGS 的思想改进生成模型。具体而言，以 GaussianDiffusion 为例：对 Diffusion 的处理与其

他方法类似，是通过添加 Lora 层调整 Diffusion；方法使用重建的高斯点云的几何一致优化 Lora 层。与 NeRF 不同，高斯方法给出了完全显式的空间几何信息。通过对高斯的几何监督，设计消除 Janus problem 和其他不一致的监督函数，再将梯度传导给 Lora 层，优化一致性。

在此之后，其他团队基于 Zero123 进一步提出了 Zero123++[25] 进行改进。首先，参考了 SyncDreamer 的方法，Zero123++ 也采用的联合扩散的思路，同步生成多个视角。Zero123++ 还添加了 reference attention 机制，用于加强与输入参考纹理一致性。Zero123++ 已经在解决一致性问题上呈现出了十分优秀的结果。

## 8. References

- [1] Zilong Chen, Feng Wang, and Huaping Liu. Text-to-3d using gaussian splatting, 2023.
- [2] Jaeyoung Chung, Suyoung Lee, Hyeongjin Nam, Jaerin Lee, and Kyoung Mu Lee. Luciddreamer: Domain-free generation of 3d gaussian splatting scenes, 2023.
- [3] Matt Deitke, Ruoshi Liu, Matthew Wallingford, Huong Ngo, Oscar Michel, Aditya Kusupati, Alan Fan, Christian Laforte, Vikram Voleti, Samir Yitzhak Gadre, Eli VanderBilt, Aniruddha Kembhavi, Carl Vondrick, Georgia Gkioxari, Kiana Ehsani, Ludwig Schmidt, and Ali Farhadi. Objaverse-xl: A universe of 10m+ 3d objects, 2023.
- [4] Matt Deitke, Dustin Schwenk, Jordi Salvador, Luca Weihs, Oscar Michel, Eli VanderBilt, Ludwig Schmidt, Kiana Ehsani, Aniruddha Kembhavi, and Ali Farhadi. Objaverse: A universe of annotated 3d objects, 2022.
- [5] Sara Fridovich-Keil, Giacomo Meanti, Frederik Warburg, Benjamin Recht, and Angjoo Kanazawa. K-planes: Explicit radiance fields in space, time, and appearance, 2023.
- [6] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models, 2023.
- [7] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation, 2022.
- [8] Xinhai Li, Huaibin Wang, and Kuo-Kun Tseng. Gaussian-diffusion: 3d gaussian splatting for denoising diffusion probabilistic models with structured noise, 2023.
- [9] Yixun Liang, Xin Yang, Jiantao Lin, Haodong Li, Xiaogang Xu, and Yingcong Chen. Luciddreamer: Towards high-fidelity text-to-3d generation via interval score matching, 2023.
- [10] Minghua Liu, Ruoxi Shi, Linghao Chen, Zhuoyang Zhang, Chao Xu, Xinyue Wei, Hansheng Chen, Chong Zeng, Jiayuan Gu, and Hao Su. One-2-3-45++: Fast single image to 3d objects with consistent multi-view generation and 3d diffusion. *arXiv preprint arXiv:2311.07885*, 2023.
- [11] Minghua Liu, Chao Xu, Haian Jin, Linghao Chen, Zexiang Xu, Hao Su, et al. One-2-3-45: Any single image to 3d mesh in 45 seconds without per-shape optimization. *arXiv preprint arXiv:2306.16928*, 2023.
- [12] Ruoshi Liu, Rundui Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot one image to 3d object, 2023.

- [13] Xian Liu, Xiaohang Zhan, Jiayang Tang, Ying Shan, Gang Zeng, Dahua Lin, Xihui Liu, and Ziwei Liu. Humangaussian: Text-driven 3d human generation with gaussian splatting. *arXiv preprint arXiv:2311.17061*, 2023.
- [14] Yuan Liu, Cheng Lin, Zijiao Zeng, Xiaoxiao Long, Lingjie Liu, Taku Komura, and Wenping Wang. Syncdreamer: Learning to generate multiview-consistent images from a single-view image. *arXiv preprint arXiv:2309.03453*, 2023.
- [15] Xiaoxiao Long, Yuan-Chen Guo, Cheng Lin, Yuan Liu, Zhiyang Dou, Lingjie Liu, Yuexin Ma, Song-Hai Zhang, Marc Habermann, Christian Theobalt, et al. Wonder3d: Single image to 3d using cross-domain diffusion. *arXiv preprint arXiv:2310.15008*, 2023.
- [16] Xiaoxiao Long, Cheng Lin, Peng Wang, Taku Komura, and Wenping Wang. Sparseneus: Fast generalizable neural surface reconstruction from sparse views, 2022.
- [17] Luke Melas-Kyriazi, Christian Rupprecht, Iro Laina, and Andrea Vedaldi. Realfusion: 360deg reconstruction of any object from a single image, 2023.
- [18] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. Nerf: Representing scenes as neural radiance fields for view synthesis, 2020.
- [19] Thomas Müller, Alex Evans, Christoph Schied, and Alexander Keller. Instant neural graphics primitives with a multiresolution hash encoding. *ACM Trans. Graph.*, 41(4):102:1–102:15, July 2022.
- [20] Michael Niemeyer, Jonathan T. Barron, Ben Mildenhall, Mehdi S. M. Sajjadi, Andreas Geiger, and Noha Radwan. Regnerf: Regularizing neural radiance fields for view synthesis from sparse inputs, 2021.
- [21] Ben Poole, Ajay Jain, Jonathan T. Barron, and Ben Mildenhall. Dreamfusion: Text-to-3d using 2d diffusion, 2022.
- [22] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021.
- [23] Barbara Roessle, Norman Müller, Lorenzo Porzi, Samuel Rota Bulò, Peter Kotschieder, and Matthias Niessner. Ganerf: Leveraging discriminators to optimize neural radiance fields. *ACM Transactions on Graphics*, 42(6):1–14, December 2023.
- [24] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [25] Ruoxi Shi, Hansheng Chen, Zhuoyang Zhang, Minghua Liu, Chao Xu, Xinyue Wei, Linghao Chen, Chong Zeng, and Hao Su. Zero123++: a single image to consistent multi-view diffusion base model, 2023.
- [26] Zifan Shi, Sida Peng, Yinghao Xu, Andreas Geiger, Yiyi Liao, and Yujun Shen. Deep generative models on 3d representations: A survey, 2023.
- [27] Jiayang Tang, Jiawei Ren, Hang Zhou, Ziwei Liu, and Gang Zeng. Dreamgaussian: Generative gaussian splatting for efficient 3d content creation. *arXiv preprint arXiv:2309.16653*, 2023.
- [28] Alexander Vilessov, Pradyumna Chari, and Achuta Kadambi. Cg3d: Compositional generation for text-to-3d via gaussian splatting. *Arxiv*, 2023.
- [29] Zhengyi Wang, Cheng Lu, Yikai Wang, Fan Bao, Chongxuan Li, Hang Su, and Jun Zhu. Prolificdreamer: High-fidelity and diverse text-to-3d generation with variational score distillation, 2023.
- [30] Jiajun Wu, Chengkai Zhang, Tianfan Xue, William T Freeman, and Joshua B Tenenbaum. Learning a probabilistic latent space of object shapes via 3d generative-adversarial modeling. In *Advances in Neural Information Processing Systems*, pages 82–90, 2016.
- [31] Rundt Wu, Ben Mildenhall, Philipp Henzler, Keunhong Park, Ruiqi Gao, Daniel Watson, Pratul P. Srinivasan, Dor Verbin, Jonathan T. Barron, Ben Poole, and Aleksander Holynski. Reconfusion: 3d reconstruction with diffusion priors, 2023.
- [32] Jamie Wynn and Daniyar Turmukhambetov. Diffusionerf: Regularizing neural radiance fields with denoising diffusion models, 2023.
- [33] Jiawei Yang, Marco Pavone, and Yue Wang. Freenerf: Improving few-shot neural rendering with free frequency regularization, 2023.
- [34] Taoran Yi, Jiemin Fang, Guanjin Wu, Lingxi Xie, Xiaopeng Zhang, Wenyu Liu, Qi Tian, and Xinggang Wang. Gaussian-dreamer: Fast generation from text to 3d gaussian splatting with point cloud priors. *arxiv:2310.08529*, 2023.
- [35] Alex Yu, Sara Fridovich-Keil, Matthew Tancik, Qinhong Chen, Benjamin Recht, and Angjoo Kanazawa. Plenoxels: Radiance fields without neural networks, 2021.

## 9. 项目分工

### 9.1. 数据收集阶段分工

- 前期调研探索：卜家梓、张致远。
- Sketchfab 网站数据的收集与筛选：卜家梓、张致远。
- ObjaverseXL 数据获取工具编写：王凯灵。
- 基于单视图的二次筛选：王凯灵、卜家梓、张致远。

### 9.2. 模型测评阶段分工

- 集群部署运行：卜家梓、张致远。
- 本地部署运行与相关批处理编写：王凯灵。
- 多视图渲染：王凯灵、张致远。
- 结果可视化：王凯灵、卜家梓。
- 测评数据分析：王凯灵、卜家梓、张致远。
- 测试其他单视图重建方法：卜家梓。

### 9.3. 报告撰写分工

- 王凯灵：任务分析与相关工作、ObjaverseXL 模型获取、模型的部署与运行、结果评价与分析、多视角一致性改进与相关工作综述、全文二次修改。

- 卜家梓: 摘要、任务分析与相关工作、Sketchfab 模型获取、模型的部署与运行、其他单视图重建方案的对比分析、多视角一致性改进与相关工作综述。
- 张致远: 任务分析与相关工作、Sketchfab 模型获取、爬虫脚本、数据清洗、多视角一致性改进与相关工作综述、全文检查。

#### 9.4. 开源数据说明

所有脚本、修改过的 One-2-3-45 代码、各个阶段所有中间数据开源于 <http://download.loping151.com/ml2023> (请参考[readme](#)和[文件说明](#))。截至报告完成撰写时, 可通过校园网 ipv4 网络直接访问。如无法访问, 可尝试通过 ipv6 网络或其他方法进行访问, 或向维护者[发送邮件](#)。